



Université Paris 1 Panthéon-Sorbonne
Master 1 Mathématiques Appliquées à
l'économie et à la finance

Théorie des Mesures de Risque

Travail d'Étude et de Recherche

Mehdi Zaoui & Zakarya Sellami

Mai 2026

Résumé

Ce travail présente la théorie axiomatique des mesures de risque, depuis les fondements probabilistes jusqu'aux applications pratiques en gestion quantitative. Nous introduisons le cadre général (capital requis, ensembles d'acceptabilité), les deux grandes classes : mesures cohérentes et convexes, et nous étudions en détail la Value-at-Risk et l'Expected Shortfall. Nous développons ensuite le théorème de représentation, les méthodes d'allocation du capital par le principe d'Euler, et les techniques d'estimation et de backtesting. Chaque thème est illustré par des exemples numériques et, le cas échéant, du code Python commenté, afin de rendre les résultats théoriques directement exploitables.

Remerciements

Nous remercions **M. Frikha** pour ses conseils et sa disponibilité tout au long de ce travail.

Table des matières

Introduction générale	3
1 Cadre probabiliste et modélisation des pertes	5
1.1 Espace de probabilité et variables aléatoires de perte	5
1.2 Notion de mesure de risque	5
1.3 Propriétés souhaitables	5
1.4 Lien avec la gestion des risques financiers	6
1.5 Portefeuilles utilisés dans le mémoire	6
2 Mesures de risque cohérentes et convexes	8
2.1 Axiomes d'Artzner-Delbaen-Eber-Heath	8
2.2 Ensembles d'acceptabilité	9
2.3 Théorème de représentation en espace fini	9
2.4 Mesures de risque convexes	10
2.5 Loi-invariance et mesures spectrales	11
2.6 Allocation de capital par le principe d'Euler	12
3 La Value-at-Risk	14
3.1 Définition et interprétation	14
3.2 Calculs explicites	14
3.2.1 Loi normale	14
3.2.2 Loi de Pareto	15
3.3 Propriétés de la VaR : trois axiomes sur quatre	16
3.4 La VaR n'est pas cohérente	16
4 Expected Shortfall et mesures de queue	18
4.1 Limites de la VaR comme motivation	18
4.2 Définition de l'Expected Shortfall	18
4.3 Calculs explicites	19
4.3.1 Loi normale	19

4.3.2	Loi de Pareto	19
4.4	Cohérence de l'Expected Shortfall	19
4.5	ES et régulation : le passage de Bâle II à Bâle IV	21
5	Validation empirique : backtesting et stress testing	22
5.1	Méthodologie et estimation	22
5.2	Backtesting de la VaR	23
5.3	Sensibilité du backtesting à la taille de fenêtre	26
5.4	Backtesting de l'Expected Shortfall	26
5.5	Stress testing : les crises de 2008 et 2020	27
5.6	Allocation d'Euler : décomposition du risque par actif	29
5.7	Synthèse	29
6	Optimisation de portefeuille par minimisation de la CVaR	31
6.1	Le problème de minimisation de la CVaR	31
6.2	Application au portefeuille	31
	Conclusion	33
A	Code Python	34
A.1	Estimateurs de la VaR et de l'ES	34
A.2	Tests de Backtesting	35
A.3	Optimisation CVaR (Rockafellar-Uryasev, programme linéaire)	36
A.4	Allocation d'Euler des Contributions à l'ES	37
B	Rappels sur les quantiles	38

Pourquoi mesurer le risque ?

En finance, le risque apparaît dès qu'une position peut entraîner une perte future. Pour un investisseur, une banque ou un gérant de portefeuille, anticiper le rendement moyen ne suffit pas : il faut aussi estimer les pertes possibles, en particulier les pertes sévères. C'est le rôle des mesures de risque.

La crise financière de 2008 l'a montré : certains modèles sous-estimaient les pertes extrêmes, notamment lorsque les corrélations entre actifs augmentent brutalement et que la liquidité se réduit. Le choc de mars 2020, lié à la pandémie de COVID-19, l'a rappelé autrement : une perte importante peut se concentrer sur quelques séances. D'où l'intérêt de mesures qui renseignent sur la queue de la distribution, et pas seulement sur un seuil.

La Value-at-Risk a longtemps été l'outil central du risque de marché. Son principe est simple : un niveau de perte qu'on ne dépasse qu'avec une probabilité fixée. Cette simplicité explique le succès de la Value-at-Risk, mais elle crée aussi des limites. En particulier, la VaR ne précise pas l'ampleur des pertes quand le seuil est franchi. L'Expected Shortfall résout ce problème en mesurant la perte moyenne dans les pires scénarios. Cette mesure est aujourd'hui la référence du cadre FRTB pour le risque de marché.

Problématique

Ce mémoire s'articule autour de la question suivante :

Quelles propriétés doit satisfaire une mesure de risque, et comment les principales mesures utilisées en finance se comportent-elles sur le plan théorique et empirique ?

Pour y répondre, nous adoptons deux points de vue. Le premier est axiomatique : une mesure de risque est étudiée à partir de propriétés comme la monotonie, l'invariance par translation, l'homogénéité positive, la sous-additivité et la convexité. Ce cadre permet de comprendre pourquoi certaines mesures sont dites cohérentes, et pourquoi la VaR ne l'est pas en général.

Le second point de vue est empirique. Les mesures de risque sont estimées sur un portefeuille construit à partir de données de marché, puis évaluées par backtesting et stress testing. Cette partie permet de confronter les propriétés théoriques des mesures aux difficultés rencontrées sur des données réelles : queues épaisses, ruptures de régime, dépendance temporelle des pertes et concentration des dépassements en période de crise.

Deux exemples accompagneront l'analyse. Le premier est un portefeuille simplifié à deux actifs, utilisé pour les calculs explicites et les contre-exemples. Le second est un portefeuille empirique équipondéré composé du S&P 500, du CAC 40, d'Apple et de TotalEnergies, observé sur la période 2008–2025.

Plan du mémoire

Le mémoire est organisé en six chapitres.

Le **chapitre 1** pose le cadre probabiliste : variables aléatoires de perte, quantiles, et définition générale d'une mesure de risque. Les propriétés souhaitables sont introduites intuitivement avant d'être formalisées dans la suite, et le portefeuille empirique est présenté en détail.

Le **chapitre 2** développe le cadre général des mesures de risque cohérentes et convexes, avec le théorème de représentation et ses implications économiques (allocation de capital, mesures spectrales).

Le **chapitre 3** est consacré à la Value-at-Risk : définition, calculs explicites sur lois usuelles, propriétés et limites, en particulier l'absence de sous-additivité, illustrée par un contre-exemple construit sur le portefeuille jouet $\Pi = A + B$.

Le **chapitre 4** introduit l'Expected Shortfall, en montre les avantages par rapport à la VaR et démontre rigoureusement sa sous-additivité.

Le **chapitre 5** confronte les outils théoriques au portefeuille empirique : estimation des mesures de risque par approches historique, paramétrique et Monte Carlo, *backtesting* de la VaR (Kupiec, Christoffersen) et de l'ES, et *stress test* sur les crises de 2008 et 2020.

Le **chapitre 6** referme le mémoire sur l'optimisation de portefeuille par minimisation de la CVaR, comparée au portefeuille de variance minimale de Markowitz.

1 Cadre probabiliste et modélisation des pertes

On fixe d'abord le cadre dans lequel les mesures de risque seront définies. Le point de départ est une variable aléatoire représentant une perte : les pertes sont comptées positivement et les gains négativement. Cette convention sera conservée dans tout le mémoire.

1.1 Espace de probabilité et variables aléatoires de perte

On se place sur un espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$, où Ω désigne l'ensemble des scénarios possibles, $\mathcal{F}$ une tribu, et $\mathbb{P}$ une probabilité de référence.

Définition 1.1 (Variable aléatoire de perte). Une variable aléatoire de perte est une variable aléatoire réelle

$$X : \Omega \rightarrow \mathbb{R}.$$

Par convention, $X(\omega) > 0$ représente une perte et $X(\omega) < 0$ représente un gain dans le scénario ω .

On note $\mathcal{X}$ l'espace des variables aléatoires de perte considérées. Dans la partie théorique, on travaillera principalement sur $L^\infty(\Omega, \mathcal{F}, \mathbb{P})$, afin d'éviter les difficultés techniques liées aux pertes non bornées. Cette hypothèse est restrictive, mais suffisante pour présenter les principaux résultats du mémoire. Dans la partie empirique, les pertes sont naturellement obtenues à partir de séries de rendements observés.

1.2 Notion de mesure de risque

Définition 1.2 (Mesure de risque). Une mesure de risque est une application

$$\rho : \mathcal{X} \rightarrow \mathbb{R} \cup \{+\infty\}$$

qui associe à une variable de perte X un nombre $\rho(X)$, interprété comme le capital à mettre en réserve pour couvrir le risque associé à X .

Lorsque $\rho(X) > 0$, la position nécessite un capital positif. Lorsque $\rho(X) \leq 0$, la position est considérée comme acceptable au regard du critère retenu. Vue comme un capital requis, la mesure de risque se relie directement à la gestion financière.

1.3 Propriétés souhaitables

Une mesure de risque doit vérifier un minimum de propriétés économiques. Les principales sont les suivantes :

- **Monotonie** : si une perte est toujours plus élevée qu'une autre, son risque doit être plus élevé.
- **Invariance par translation** : ajouter une perte certaine augmente le capital requis du même montant.
- **Homogénéité positive** : multiplier la taille d'une position multiplie son risque dans les mêmes proportions.
- **Sous-additivité** : le risque d'un portefeuille ne doit pas dépasser la somme des risques de ses composantes.

- **Convexité** : diversifier entre deux positions ne doit pas augmenter le risque au-delà de la moyenne pondérée des risques initiaux.

Ces propriétés seront formalisées au chapitre suivant. La sous-additivité jouera un rôle particulier, car elle permet de distinguer la VaR de l'Expected Shortfall : la première ne la vérifie pas en général, tandis que la seconde est cohérente.

1.4 Lien avec la gestion des risques financiers

Dans une institution financière, une mesure de risque sert principalement à trois choses.

D'abord, elle permet de calculer un *capital économique*, c'est-à-dire une estimation interne du capital nécessaire pour absorber les pertes potentielles. Ce capital dépend du portefeuille, de l'horizon retenu et du niveau de confiance choisi.

Ensuite, elle intervient dans le calcul du *capital réglementaire*. Les exigences en fonds propres imposées aux banques s'appuient sur des mesures de risque standardisées. Historiquement, la VaR a joué un rôle central ; l'Expected Shortfall l'a progressivement remplacée dans le cadre du risque de marché.

Enfin, une mesure de risque permet de répartir le risque agrégé entre différentes composantes du portefeuille. Cette question d'allocation sera étudiée plus loin à l'aide du principe d'Euler.

1.5 Portefeuilles utilisés dans le mémoire

Deux portefeuilles seront utilisés dans la suite.

Le premier est un portefeuille simplifié à deux actifs, noté

$$\Pi = A + B.$$

Si X_A et X_B désignent les pertes des deux actifs, la perte du portefeuille est

$$X_\Pi = X_A + X_B.$$

Ce portefeuille servira aux calculs explicites et aux contre-exemples, notamment pour illustrer la non-sous-additivité de la VaR.

Le second est un portefeuille empirique construit à partir de données quotidiennes téléchargées avec la bibliothèque `yfinance`. Il est composé de quatre actifs équipondérés :

$$\text{S\&P 500, CAC 40, Apple, TotalEnergies.}$$

La période d'étude va de 2008 à 2025, ce qui permet d'inclure la crise financière de 2008 et le choc de mars 2020.

Les rendements quotidiens sont calculés en log-rendements :

$$r_t = \ln \left(\frac{S_t}{S_{t-1}} \right),$$

et les pertes sont définies par

$$X_t = -r_t.$$

Le tableau suivant présente les statistiques descriptives des rendements quotidiens sur la période étudiée.

Statistiques descriptives. Le tableau 1 résume les principales caractéristiques empiriques des rendements.

Actif	Moyenne	Écart-type	Skewness	Kurtosis	Max drawdown
S&P 500	0,03%	1,27%	−0,46	15,52	−53,25%
CAC 40	0,01%	1,38%	−0,27	11,18	−54,58%
AAPL	0,09%	1,97%	−0,31	10,38	−59,88%
TTE.PA	0,02%	1,74%	−0,27	14,14	−58,69%

TABLE 1 – Statistiques descriptives des rendements quotidiens, période 2008-2025.

Les kurtosis élevées indiquent la présence de queues plus épaisses que celles d’une loi normale. Les skewness négatives traduisent une asymétrie vers les pertes extrêmes. Ces deux éléments justifient l’utilisation de mesures de risque adaptées aux queues de distribution, en particulier l’Expected Shortfall.

La suite du mémoire est organisée autour de l’étude de deux mesures de risque : la Value-at-Risk et l’Expected Shortfall. La première, très répandue, ne vérifie pourtant pas toutes les propriétés souhaitables : c’est ce qui motive l’introduction de la seconde.

2 Mesures de risque cohérentes et convexes

Le chapitre précédent a introduit les propriétés attendues d'une mesure de risque. On les formalise ici à travers les mesures cohérentes, introduites par Artzner, Delbaen, Eber et Heath [1]. Pour un panorama d'ensemble de la gestion quantitative des risques, on renvoie à [2]. Ce cadre juge une mesure de risque sur ses propriétés mathématiques, et non sur son seul usage pratique.

L'enjeu principal est la diversification. Une mesure de risque cohérente doit en particulier satisfaire la sous-additivité : le risque d'un portefeuille ne doit pas dépasser la somme des risques de ses composantes. Cette propriété sera déterminante dans la comparaison entre la Value-at-Risk et l'Expected Shortfall.

2.1 Axiomes d'Artzner-Delbaen-Eber-Heath

Définition 2.1 (Mesure de risque cohérente). Une mesure de risque $\rho : \mathcal{X} \rightarrow \mathbb{R}$ est dite *cohérente* si elle satisfait les quatre axiomes suivants :

1. **monotonie** : $X \leq Y$ p.s. $\Rightarrow \rho(X) \leq \rho(Y)$;
2. **invariance par translation** : $\rho(X + c) = \rho(X) + c$ pour tout $c \in \mathbb{R}$;
3. **homogénéité positive** : $\rho(\lambda X) = \lambda \rho(X)$ pour tout $\lambda > 0$;
4. **sous-additivité** : $\rho(X + Y) \leq \rho(X) + \rho(Y)$.

Chacun de ces axiomes admet une lecture économique précise. La *monotonie* est une exigence de rationalité minimale : un risque uniformément plus grand ne peut pas recevoir un capital plus petit. L'*invariance par translation* formalise le rôle du cash comme instrument de couverture parfait : ajouter c unités de cash à une position réduit le capital requis de c , ce qui s'écrit aussi $\rho(X - \rho(X)) = 0$ et signifie qu'après mise en réserve de $\rho(X)$, la position ajustée est à la limite de l'acceptabilité. L'*homogénéité positive* exprime l'invariance d'échelle : le risque d'une position est proportionnel à sa taille. La *sous-additivité*, enfin, est la formalisation du principe de diversification : un portefeuille agrégé n'est jamais plus risqué que la somme de ses composantes prises séparément.

Remarque 2.2 (Convexité induite). Sous homogénéité positive, sous-additivité et convexité sont équivalentes : si ρ est sous-additive et homogène, alors pour $\lambda \in [0, 1]$,

$$\rho(\lambda X + (1 - \lambda)Y) \leq \rho(\lambda X) + \rho((1 - \lambda)Y) = \lambda \rho(X) + (1 - \lambda) \rho(Y).$$

Toute mesure cohérente est donc convexe. La réciproque est fautive en général, comme nous le verrons en section 2.4.

Exemple 2.3 (Premiers exemples). — L'espérance $\rho(X) = \mathbb{E}[X]$ est cohérente.

- Sous l'hypothèse de distributions elliptiques (en particulier gaussiennes), la *mesure de volatilité* $\rho(X) = \mathbb{E}[X] + \lambda \sigma(X)$, où $\sigma(X) = \sqrt{\text{Var}(X)}$, est cohérente pour tout $\lambda \geq 0$. Elle reste un exemple essentiel parce que sa cohérence est entièrement attribuable à la structure elliptique, et qu'elle servira de référence pour l'allocation de capital (section 2.6). Hors du cadre elliptique, elle peut violer la monotonie.
- La variance $\rho(X) = \text{Var}(X)$ n'est pas cohérente : ni monotone, ni invariante par translation, ni positivement homogène au sens usuel.

Ces exemples laissent de côté les mesures les plus utilisées en pratique, la VaR et l'Expected Shortfall, qui font l'objet des deux chapitres suivants. Le présent chapitre fournira les outils théoriques pour les classer dans la grille axiomatique : nous verrons au chapitre 3 que la VaR *n'est pas* cohérente (elle viole la sous-additivité), et au chapitre 4 que l'ES *est* cohérente.

2.2 Ensembles d'acceptabilité

À chaque mesure de risque correspond naturellement une partie distinguée de $\mathcal{X}$: l'ensemble des positions « acceptables », c'est-à-dire celles dont le capital requis est négatif ou nul. Cette correspondance traduit chaque axiome de la définition 2.1 en une propriété géométrique simple. C'est sur elle que repose le théorème de la section 2.3.

Définition 2.4 (Ensemble d'acceptabilité). Soit $\rho : \mathcal{X} \rightarrow \mathbb{R}$ une mesure de risque. Son ensemble d'acceptabilité est

$$\mathcal{A}_\rho = \{X \in \mathcal{X} : \rho(X) \leq 0\}.$$

Proposition 2.5 (Correspondance axiomes/géométrie). Soit $\rho : \mathcal{X} \rightarrow \mathbb{R}$ monotone et invariante par translation. Alors :

1. Pour tout $X \in \mathcal{X}$, $\rho(X) = \inf\{c \in \mathbb{R} : X - c \in \mathcal{A}_\rho\}$.
2. $\mathcal{A}_\rho$ est convexe si et seulement si ρ est convexe.
3. $\mathcal{A}_\rho$ est un cône si et seulement si ρ est positivement homogène.

En particulier, ρ est cohérente si et seulement si $\mathcal{A}_\rho$ est un cône convexe.

Démonstration. Point 1. Par invariance par translation, $\rho(X - c) = \rho(X) - c$, donc $X - c \in \mathcal{A}_\rho$ équivaut à $\rho(X) \leq c$. L'infimum sur de tels c est précisément $\rho(X)$.

Point 2. Si ρ est convexe et $X, Y \in \mathcal{A}_\rho$, alors pour $\lambda \in [0, 1]$ on a $\rho(\lambda X + (1 - \lambda)Y) \leq \lambda \rho(X) + (1 - \lambda)\rho(Y) \leq 0$, donc $\lambda X + (1 - \lambda)Y \in \mathcal{A}_\rho$. Réciproquement, si $\mathcal{A}_\rho$ est convexe, posons pour tous X, Y et $\lambda \in [0, 1]$ les valeurs $c_X = \rho(X)$, $c_Y = \rho(Y)$. Les éléments $X - c_X$ et $Y - c_Y$ appartiennent à $\mathcal{A}_\rho$ (point 1), et par convexité $\lambda(X - c_X) + (1 - \lambda)(Y - c_Y) \in \mathcal{A}_\rho$, soit $\rho(\lambda X + (1 - \lambda)Y) \leq \lambda c_X + (1 - \lambda)c_Y$.

Point 3. Analogue, en utilisant l'invariance par translation et l'homogénéité. $\square$

Cette proposition donne une lecture entièrement géométrique des axiomes : une mesure cohérente est une fonctionnelle qui mesure la « distance verticale » (au sens de la translation par un scalaire) entre une position X et un cône convexe de positions acceptables. C'est cette lecture géométrique qui sert de base au théorème de représentation établi ci-dessous.

2.3 Théorème de représentation en espace fini

Plaçons-nous dans le cas où $\Omega = \{\omega_1, \dots, \omega_n\}$ est fini, muni d'une probabilité de référence $\mathbb{P}$ qui charge tous les points. Sous cette hypothèse, $\mathcal{X}$ s'identifie à $\mathbb{R}^n$, et le théorème de séparation des convexes en dimension finie (Hahn-Banach) suffit pour établir le résultat suivant ; le cas d'un espace de probabilité général est dû à Delbaen [10].

Théorème 2.6 (Représentation des mesures cohérentes, cas fini). Soit $\rho : \mathbb{R}^n \rightarrow \mathbb{R}$. Les deux assertions suivantes sont équivalentes :

1. ρ est une mesure de risque cohérente ;

2. il existe un ensemble convexe et fermé $\mathcal{Q}$ de mesures de probabilité sur Ω tel que

$$\rho(X) = \sup_{Q \in \mathcal{Q}} \mathbb{E}_Q[X], \quad X \in \mathbb{R}^n.$$

Démonstration. ($\Leftarrow$) Supposons que $\rho(X) = \sup_{Q \in \mathcal{Q}} \mathbb{E}_Q[X]$.

La *monotonie* est immédiate : si $X \leq Y$ p.s., alors $\mathbb{E}_Q[X] \leq \mathbb{E}_Q[Y]$ pour tout Q , donc le sup conserve l'inégalité.

L'*invariance par translation* découle de $\mathbb{E}_Q[c] = c$ pour toute probabilité Q et tout $c \in \mathbb{R}$: $\sup_Q \mathbb{E}_Q[X + c] = \sup_Q (\mathbb{E}_Q[X] + c) = \rho(X) + c$.

L'*homogénéité positive* suit de la linéarité de $\mathbb{E}_Q$: $\sup_Q \mathbb{E}_Q[\lambda X] = \lambda \sup_Q \mathbb{E}_Q[X]$ pour $\lambda > 0$.

La *sous-additivité* découle de $\sup_Q (\mathbb{E}_Q[X] + \mathbb{E}_Q[Y]) \leq \sup_Q \mathbb{E}_Q[X] + \sup_Q \mathbb{E}_Q[Y]$ et de $\mathbb{E}_Q[X + Y] = \mathbb{E}_Q[X] + \mathbb{E}_Q[Y]$.

($\Rightarrow$) Soit ρ cohérente. Par la proposition 2.5, $\mathcal{A}_\rho \subset \mathbb{R}^n$ est un cône convexe fermé, et $\rho(X) = \inf\{c : X - c \in \mathcal{A}_\rho\}$.

Le théorème de séparation des convexes (Hahn-Banach en dimension finie) appliqué à $\mathcal{A}_\rho$ fournit l'existence d'une famille de formes linéaires positives qui caractérisent $\mathcal{A}_\rho$. Après normalisation pour obtenir des vecteurs de probabilités $q \in \mathbb{R}_+^n$ avec $\sum_i q_i = 1$, on définit

$$\mathcal{Q} = \left\{ q \in \mathbb{R}_+^n : \sum_i q_i = 1 \text{ et } \sum_i q_i X_i \leq 0 \ \forall X \in \mathcal{A}_\rho \right\},$$

qui est convexe, fermé, et satisfait $\rho(X) = \sup_{q \in \mathcal{Q}} \sum_i q_i X(\omega_i)$. $\square$

Remarque 2.7 (Interprétation économique). Une mesure cohérente est toujours un *pire cas* sur un ensemble de scénarios probabilistes alternatifs $\mathcal{Q}$. Chaque $Q \in \mathcal{Q}$ représente un « modèle de risque » possible, et $\rho(X)$ est l'espérance de perte calculée sous le modèle le plus défavorable. On peut donc lire une mesure cohérente comme une aversion au risque de modèle : l'institution refuse de parier sur une seule probabilité parmi plusieurs jugées plausibles. Nous verrons au chapitre 4 que l'Expected Shortfall admet une telle représentation avec un ensemble $\mathcal{Q}$ explicite, caractérisé par une borne sur la densité de Radon-Nikodym par rapport à $\mathbb{P}$.

2.4 Mesures de risque convexes

L'homogénéité positive impose que doubler la taille d'une position double exactement le risque. Cette hypothèse peut être trop restrictive en présence d'effets non linéaires : illiquidité (une grande position est plus difficile à liquider), impact de marché (l'exécution même de la liquidation déplace les prix), risque de concentration. Dans tous ces cas, doubler la taille *augmente plus que linéairement* le risque. On souhaite alors affaiblir l'homogénéité tout en conservant la diversification.

Définition 2.8 (Mesure de risque convexe). Une mesure de risque $\rho : \mathcal{X} \rightarrow \mathbb{R}$ est dite *convexe* si elle est :

1. monotone,
2. invariante par translation,
3. convexe : pour tous $X, Y \in \mathcal{X}$ et $\lambda \in [0, 1]$, $\rho(\lambda X + (1 - \lambda)Y) \leq \lambda \rho(X) + (1 - \lambda) \rho(Y)$.

Proposition 2.9. *Toute mesure cohérente est convexe. La réciproque est fausse.*

Exemple 2.10 (Mesure entropique). Soit $\theta > 0$. La *mesure entropique* de paramètre θ est

$$\rho_\theta(X) = \frac{1}{\theta} \ln \mathbb{E}[e^{\theta X}].$$

Cette mesure est convexe mais pas positivement homogène. La convexité résulte de l'inégalité de Hölder : pour $\lambda \in [0, 1]$,

$$\mathbb{E}[e^{\theta(\lambda X + (1-\lambda)Y)}] = \mathbb{E}[(e^{\theta X})^\lambda (e^{\theta Y})^{1-\lambda}] \leq \mathbb{E}[e^{\theta X}]^\lambda \mathbb{E}[e^{\theta Y}]^{1-\lambda},$$

puis prendre $\frac{1}{\theta} \ln$. La non-homogénéité provient de

$$\rho_\theta(\lambda X) = \frac{1}{\theta} \ln \mathbb{E}[e^{(\theta\lambda)X}],$$

expression qui dépend du paramètre $\theta\lambda$ et n'est pas proportionnelle à $\rho_\theta(X)$.

L'analogue du théorème de représentation existe pour les mesures convexes, au prix de l'introduction d'une *fonction de pénalité* qui quantifie le « coût » de chaque modèle.

2.5 Loi-invariance et mesures spectrales

Définition 2.11 (Loi-invariance). Une mesure de risque ρ est *loi-invariante* si pour tous $X, Y \in \mathcal{X}$ ayant même loi sous $\mathbb{P}$, $\rho(X) = \rho(Y)$.

La loi-invariance est une propriété naturelle : si deux positions ont la même distribution des pertes, elles doivent recevoir le même capital. Une classe importante de mesures cohérentes loi-invariantes est constituée par les *mesures spectrales*, qui s'expriment comme moyennes pondérées des quantiles.

Définition 2.12 (Mesure spectrale). Une *mesure spectrale* est une mesure de risque de la forme

$$\rho_\phi(X) = \int_0^1 \phi(u) q_u(X) du,$$

où $\phi : (0, 1) \rightarrow [0, +\infty)$ est positive, *croissante*, et normalisée : $\int_0^1 \phi(u) du = 1$.

Remarque 2.13 (Convention de monotonie). La croissance de ϕ correspond à la convention « pertes positives » adoptée dans ce mémoire : les grands quantiles correspondent aux pertes sévères, qui doivent recevoir un poids plus important. Dans la convention duale (Acerbi 2002, en termes de gains), on travaille avec une fonction décroissante.

Le profil de ϕ encode l'aversion au risque : une fonction constante donne l'espérance, et plus ϕ se concentre près de $u = 1$, plus la mesure pénalise les pertes extrêmes. Un choix particulièrement simple, $\phi(u) = \frac{1}{1-\alpha} \mathbf{1}_{u>\alpha}$, qui place tout le poids sur les quantiles supérieurs à un seuil α , donne lieu à la mesure que nous étudierons en détail au chapitre 4 sous le nom d'*Expected Shortfall*. Les mesures spectrales constituent ainsi une famille paramétrique flexible, et l'ES en est l'instance la plus simple.

2.6 Allocation de capital par le principe d'Euler

Une fois la mesure ρ choisie et le capital agrégé $\rho(X_\Pi)$ calculé pour le portefeuille global $\Pi = X_1 + \dots + X_n$ d'une banque, se pose la question de la *décomposition* en contributions ρ_i par activité. On souhaite une décomposition cohérente, satisfaisant $\sum_i \rho_i = \rho(X_\Pi)$: le capital total doit être exactement réparti, sans création ni perte. Le *principe d'Euler* fournit une telle décomposition pour les mesures positivement homogènes et différentiables.

Théorème 2.14 (Allocation par Euler). *Soit ρ une mesure de risque positivement homogène et différentiable en X_Π dans toutes les directions X_i , $i = 1, \dots, n$. Posons*

$$\rho_i = \left. \frac{d}{dt} \rho(X_\Pi + tX_i) \right|_{t=0}.$$

Alors $\sum_{i=1}^n \rho_i = \rho(X_\Pi)$.

Démonstration. Par homogénéité positive, $\rho(\lambda X_\Pi) = \lambda \rho(X_\Pi)$ pour tout $\lambda > 0$. En dérivant par rapport à λ en $\lambda = 1$ et en utilisant la décomposition $X_\Pi = \sum_i X_i$:

$$\rho(X_\Pi) = \left. \frac{d}{d\lambda} \rho(\lambda X_\Pi) \right|_{\lambda=1} = \sum_{i=1}^n \left. \frac{d}{dt} \rho(X_\Pi + tX_i) \right|_{t=0} = \sum_{i=1}^n \rho_i.$$

□

L'allocation Euler dépend bien sûr du choix de ρ . Pour la mesure de volatilité $\rho(X) = \mathbb{E}[X] + \lambda \sigma(X)$ introduite à l'exemple 2.3, le calcul est explicite et donne une formule particulièrement parlante.

Exemple 2.15 (Allocation Euler sur le portefeuille jouet). Reprenons le portefeuille fil rouge $\Pi = A + B$ avec

$$X_A \sim \mathcal{N}(0, \sigma_A^2), \quad X_B \sim \mathcal{N}(0, \sigma_B^2), \quad \text{Cov}(X_A, X_B) = \rho \sigma_A \sigma_B,$$

où $\rho \in [-1, 1]$ est le coefficient de corrélation. Alors $X_\Pi \sim \mathcal{N}(0, \sigma_\Pi^2)$ avec $\sigma_\Pi^2 = \sigma_A^2 + \sigma_B^2 + 2\rho \sigma_A \sigma_B$.

Pour la mesure de volatilité $\rho_\lambda(X) = \mathbb{E}[X] + \lambda \sigma(X)$ appliquée au portefeuille de pertes nulles en moyenne, on a simplement $\rho_\lambda(X_\Pi) = \lambda \sigma_\Pi$. La dérivée directionnelle de σ par rapport à X_A vaut

$$\left. \frac{d}{dt} \sigma(X_\Pi + tX_A) \right|_{t=0} = \frac{\text{Cov}(X_\Pi, X_A)}{\sigma_\Pi} = \frac{\sigma_A^2 + \rho \sigma_A \sigma_B}{\sigma_\Pi},$$

de sorte que

$$\rho_A^{\text{Euler}} = \lambda \cdot \frac{\sigma_A^2 + \rho \sigma_A \sigma_B}{\sigma_\Pi} = \frac{\sigma_A^2 + \rho \sigma_A \sigma_B}{\sigma_\Pi^2} \rho_\lambda(X_\Pi),$$

et symétriquement

$$\rho_B^{\text{Euler}} = \frac{\sigma_B^2 + \rho \sigma_A \sigma_B}{\sigma_\Pi^2} \rho_\lambda(X_\Pi).$$

La somme vaut $\frac{\sigma_A^2 + \sigma_B^2 + 2\rho \sigma_A \sigma_B}{\sigma_\Pi^2} \rho_\lambda(X_\Pi) = \rho_\lambda(X_\Pi)$, conformément au théorème 2.14.

Lecture financière. Pour $\sigma_A = \sigma_B = 1$ et $\rho = 0$, on obtient $\rho_A^{\text{Euler}} = \rho_B^{\text{Euler}} = \frac{1}{2} \rho_\lambda(X_\Pi)$ par symétrie. Pour $\sigma_A = 1$, $\sigma_B = 3$ et $\rho = 0$, en revanche, le rapport $\rho_A^{\text{Euler}} / \rho_B^{\text{Euler}} = 1/9$: le desk B reçoit 90% du capital, ce qui correspond à sa contribution quadratique au risque agrégé. On voit ici pourquoi l'allocation d'Euler est plus informative qu'une répartition au prorata des tailles : la contribution croît comme le carré de la volatilité (ici B pèse neuf fois A), et la formule générale tient en plus compte des corrélations

Remarque 2.16 (Allocation Euler de l'ES). Les coefficients d'allocation $\frac{\sigma_i^2 + \rho_{ij}\sigma_i\sigma_j}{\sigma_\Pi^2}$ obtenus dans l'exemple 2.15 dépendent uniquement de la covariance et non du coefficient λ . Ils sont donc valables pour toute mesure de risque s'écrivant comme $c \cdot \sigma(\cdot)$ avec c indépendant de la position, en particulier pour l'ES sous loi gaussienne, comme nous le retrouverons au chapitre 4.

Le cadre axiomatique développé dans ce chapitre fournit les outils pour classer toute mesure de risque candidate. Les chapitres 3 et 4 l'appliquent successivement aux deux mesures les plus utilisées en pratique : la Value-at-Risk, qui violera la sous-additivité et ne sera donc pas cohérente, et l'Expected Shortfall, qui satisfera tous les axiomes ADEH.

3 La Value-at-Risk

La Value-at-Risk est l'une des mesures de risque les plus utilisées en pratique financière. Son succès tient à la simplicité de son interprétation et à sa facilité de communication : dire qu'une institution a une VaR à 99% d'un million d'euros sur un horizon d'un jour signifie que, selon le modèle retenu, la probabilité que la perte dépasse un million d'euros sur cet horizon est au plus égale à 1%.

Ce chapitre confronte la Value-at-Risk au cadre axiomatique développé au chapitre 2. Nous montrerons qu'elle satisfait trois des quatre axiomes ADEH (monotonie, invariance par translation, homogénéité positive) mais pas la sous-additivité : la VaR n'est donc pas une mesure cohérente. Cette défaillance, illustrée par un contre-exemple discret simple, motivera l'introduction de l'Expected Shortfall au chapitre 4.

3.1 Définition et interprétation

Définition 3.1 (Value-at-Risk). Soit X une variable aléatoire de perte et $\alpha \in (0, 1)$ un niveau de confiance. La *Value-at-Risk* de X au niveau α est définie par

$$\text{VaR}_\alpha(X) = q_\alpha(X) = \inf\{x \in \mathbb{R} : \mathbb{P}(X \leq x) \geq \alpha\}.$$

Autrement dit, la Value-at-Risk n'est rien d'autre que le quantile d'ordre α de la variable de perte X . En pratique, les niveaux de confiance les plus usuels sont $\alpha = 0,95$, $\alpha = 0,975$ et $\alpha = 0,99$.

Remarque 3.2 (Interprétation). Si $\text{VaR}_\alpha(X) = v$, alors $\mathbb{P}(X \leq v) \geq \alpha$ et, de manière équivalente, $\mathbb{P}(X > v) \leq 1 - \alpha$. La VaR fournit donc un *seuil de perte* : avec une probabilité au moins égale à α , la perte ne dépasse pas ce seuil. En revanche, elle ne dit rien sur l'ampleur des pertes lorsque ce seuil est franchi.

Cette dernière remarque est essentielle. La VaR décrit un point de la distribution mais ne renseigne pas sur la forme de la queue au-delà de ce point. Deux portefeuilles peuvent ainsi avoir la même VaR tout en présentant des comportements très différents dans les scénarios extrêmes ; c'est l'une des motivations de l'Expected Shortfall, étudiée au chapitre 4.

3.2 Calculs explicites

La simplicité de la VaR tient en partie au fait qu'elle s'obtient explicitement pour de nombreuses lois classiques. Nous présentons ici deux lois usuelles qui serviront de référence dans la suite : la loi normale et la loi de Pareto.

3.2.1 Loi normale

Supposons que

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

Alors la variable centrée réduite

$$Z = \frac{X - \mu}{\sigma}$$

suit la loi normale standard $\mathcal{N}(0, 1)$, de fonction de répartition Φ . On en déduit immédiatement

$$\mathbb{P}(X \leq x) = \Phi\left(\frac{x - \mu}{\sigma}\right),$$

puis

$$\text{VaR}_\alpha(X) = \mu + \sigma \Phi^{-1}(\alpha).$$

Exemple 3.3 (Fil rouge, VaR sous loi normale). Reprenons le portefeuille fil rouge introduit au chapitre précédent. On suppose que

$$X_A \sim \mathcal{N}(0, 1), \quad X_B \sim \mathcal{N}(0, 1),$$

et que X_A et X_B sont indépendantes. Alors

$$X_\Pi = X_A + X_B \sim \mathcal{N}(0, 2) = \mathcal{N}(0, (\sqrt{2})^2).$$

Pour un actif isolé, on obtient

$$\text{VaR}_{0,95}(X_A) = \Phi^{-1}(0,95) \approx 1,645.$$

Pour le portefeuille agrégé,

$$\text{VaR}_{0,95}(X_\Pi) = \sqrt{2} \Phi^{-1}(0,95) \approx \sqrt{2} \times 1,645 \approx 2,326.$$

Par ailleurs,

$$\text{VaR}_{0,95}(X_A) + \text{VaR}_{0,95}(X_B) = 2 \times 1,645 = 3,290.$$

On a donc

$$\text{VaR}_{0,95}(X_\Pi) \leq \text{VaR}_{0,95}(X_A) + \text{VaR}_{0,95}(X_B).$$

Dans ce cas particulier, la VaR est sous-additive. Cette propriété ne vaut toutefois pas en général.

Le cas gaussien est commode : les calculs sont explicites et la somme de normales indépendantes reste normale. C'est l'une des raisons pour lesquelles la VaR a longtemps été étudiée dans des modèles fondés sur l'hypothèse de normalité.

3.2.2 Loi de Pareto

Considérons enfin une loi de Pareto de paramètres $x_m > 0$ et $\xi > 0$, définie par la fonction de répartition

$$F_X(x) = \begin{cases} 0 & \text{si } x < x_m, \\ 1 - \left(\frac{x_m}{x}\right)^\xi & \text{si } x \geq x_m. \end{cases}$$

Pour calculer la VaR, on résout

$$1 - \left(\frac{x_m}{x}\right)^\xi = \alpha,$$

d'où

$$\left(\frac{x_m}{x}\right)^\xi = 1 - \alpha, \quad x = \frac{x_m}{(1 - \alpha)^{1/\xi}}.$$

Ainsi,

$$\text{VaR}_\alpha(X) = \frac{x_m}{(1 - \alpha)^{1/\xi}}.$$

Cette formule met en évidence le rôle des queues épaisses : lorsque α est proche de 1, la VaR peut croître très rapidement. Plus le paramètre ξ est petit, plus la queue est lourde, et plus les quantiles de haut niveau deviennent élevés.

3.3 Propriétés de la VaR : trois axiomes sur quatre

La VaR possède plusieurs propriétés mathématiques naturelles, héritées des propriétés des quantiles établies à la proposition B.2. Confrontons-la systématiquement aux quatre axiomes ADEH (définition 2.1).

Proposition 3.4 (Propriétés de la VaR). *Pour tout niveau $\alpha \in (0, 1)$, la mesure VaR_α est :*

1. **monotone** : $X \leq Y$ p.s. $\Rightarrow \text{VaR}_\alpha(X) \leq \text{VaR}_\alpha(Y)$;
2. **invariante par translation** : $\text{VaR}_\alpha(X + c) = \text{VaR}_\alpha(X) + c$ pour tout $c \in \mathbb{R}$;
3. **positivement homogène** : $\text{VaR}_\alpha(\lambda X) = \lambda \text{VaR}_\alpha(X)$ pour tout $\lambda > 0$;
4. **loi-invariante** : si X et Y ont la même loi, alors $\text{VaR}_\alpha(X) = \text{VaR}_\alpha(Y)$.

Démonstration. La monotonie et l'homogénéité positive découlent directement des propriétés élémentaires des quantiles (proposition B.2, points 4 et 3). Montrons l'invariance par translation. Soit $c \in \mathbb{R}$. Pour tout $x \in \mathbb{R}$, $F_{X+c}(x) = \mathbb{P}(X + c \leq x) = \mathbb{P}(X \leq x - c) = F_X(x - c)$. Par conséquent

$$\begin{aligned} \text{VaR}_\alpha(X + c) &= \inf\{x \in \mathbb{R} : F_{X+c}(x) \geq \alpha\} \\ &= \inf\{x \in \mathbb{R} : F_X(x - c) \geq \alpha\}. \end{aligned}$$

En posant $y = x - c$, on obtient $\text{VaR}_\alpha(X + c) = \inf\{y : F_X(y) \geq \alpha\} + c = \text{VaR}_\alpha(X) + c$. La loi-invariance est immédiate puisque $\text{VaR}_\alpha(X)$ ne dépend de X que via F_X . $\square$

La VaR satisfait donc trois des quatre axiomes ADEH (les trois premiers de la définition 2.1), ainsi que la loi-invariance. Elle laisse cependant ouverte la question de la sous-additivité, sur laquelle se joue la cohérence. La section suivante établit, par un contre-exemple, que cet axiome *n'est pas* satisfait en général.

3.4 La VaR n'est pas cohérente

La sous-additivité traduit l'idée qu'agréger deux positions ne doit pas être plus risqué que les traiter séparément. Une mesure qui viole cette propriété peut pénaliser la diversification, ce qui contredit l'intuition économique de base. Nous donnons ici un contre-exemple discret simple, fondé sur deux positions de crédit indépendantes.

Exemple 3.5 (Non-sous-additivité de la VaR). Considérons deux obligations A et B , chacune pouvant faire défaut indépendamment avec probabilité $p = 0,04$. En cas de défaut, la perte vaut 1 ; sinon, la perte vaut 0. Formellement,

$$X_A = \begin{cases} 1 & \text{avec probabilité } 0,04, \\ 0 & \text{avec probabilité } 0,96, \end{cases} \quad X_B \text{ indépendante et de même loi que } X_A.$$

Calculons la VaR au niveau $\alpha = 0,95$. Pour chaque obligation prise séparément, $\mathbb{P}(X_A \leq 0) = 0,96 \geq 0,95$, d'où $\text{VaR}_{0,95}(X_A) = \text{VaR}_{0,95}(X_B) = 0$. Ainsi $\text{VaR}_{0,95}(X_A) + \text{VaR}_{0,95}(X_B) = 0$.

Considérons maintenant le portefeuille agrégé $X_\Pi = X_A + X_B$. Sa loi est donnée par

$$\begin{aligned} \mathbb{P}(X_\Pi = 0) &= 0,96^2 = 0,9216, \\ \mathbb{P}(X_\Pi = 1) &= 2 \times 0,04 \times 0,96 = 0,0768, \\ \mathbb{P}(X_\Pi = 2) &= 0,04^2 = 0,0016. \end{aligned}$$

On en déduit $\mathbb{P}(X_{\Pi} \leq 0) = 0,9216 < 0,95$ et $\mathbb{P}(X_{\Pi} \leq 1) = 0,9984 \geq 0,95$, donc $\text{VaR}_{0,95}(X_{\Pi}) = 1$. Finalement,

$$\text{VaR}_{0,95}(X_{\Pi}) = 1 > 0 = \text{VaR}_{0,95}(X_A) + \text{VaR}_{0,95}(X_B).$$

Proposition 3.6 (La VaR n'est pas cohérente). *La VaR ne satisfait pas l'axiome de sous-additivité de la définition 2.1. Par conséquent, VaR_{α} n'est pas une mesure de risque cohérente.*

Remarque 3.7 (Interprétation). L'exemple 3.5 montre qu'une position peut apparaître sans risque au sens de la VaR lorsqu'elle est considérée isolément, alors que le portefeuille agrégé reçoit une VaR strictement positive. La VaR peut donc, dans certains cas, pénaliser l'agrégation des risques, ce qui va à l'encontre de l'intuition de diversification. Ce phénomène ne se limite pas aux distributions à queues lourdes : il peut déjà apparaître dans des modèles discrets très simples, comme ici. À l'inverse, dans certains cadres favorables, par exemple sous loi gaussienne, l'agrégation de variables normales restant normale, la sous-additivité peut être satisfaite.

Économiquement, ce défaut est gênant : une mesure censée évaluer les bénéfices de la diversification ne devrait pas pénaliser l'agrégation des risques. C'est ce que corrige l'Expected Shortfall, dont le chapitre suivant établit la cohérence.

4 Expected Shortfall et mesures de queue

Le chapitre précédent a établi que la Value-at-Risk, malgré ses qualités pratiques, n'est pas une mesure de risque cohérente : elle viole la sous-additivité (corollaire 3.6). Ce chapitre introduit l'*Expected Shortfall* (ES), aussi appelée *Conditional Value-at-Risk* (CVaR) ou *Tail Value-at-Risk* (TVaR), et démontre rigoureusement qu'elle corrige cette défaillance : l'ES satisfait les quatre axiomes ADEH et constitue donc l'instance fondamentale de mesure cohérente loi-invariante. Cohérente et sensible à la sévérité des pertes extrêmes, l'ES est la mesure retenue par Bâle IV.

4.1 Limites de la VaR comme motivation

La VaR répond à la question : « quelle est la perte maximale dans $\alpha\%$ des cas ? ». Elle ne répond pas à la question : « si les choses se passent vraiment mal, quelle perte peut-on anticiper ? ». L'ES répond précisément à cette seconde question : elle moyenne les pertes au-delà du seuil de VaR, et cette moyenne suffit à rétablir la sous-additivité.

4.2 Définition de l'Expected Shortfall

Définition 4.1 (Expected Shortfall). Soit X une variable aléatoire de perte et $\alpha \in (0, 1)$. L'*Expected Shortfall* de X au niveau α est

$$\text{ES}_\alpha(X) = \frac{1}{1-\alpha} \int_\alpha^1 \text{VaR}_u(X) du = \frac{1}{1-\alpha} \int_\alpha^1 q_u(X) du.$$

Remarque 4.2 (Clarification des dénominations). Cette mesure est connue sous plusieurs noms dans la littérature :

- *Expected Shortfall* (ES), terme utilisé notamment par Acerbi et Tasche [5, 6] ;
- *Conditional Value-at-Risk* (CVaR), terme utilisé par Rockafellar et Uryasev [4] ;
- *Tail Value-at-Risk* (TVaR), terme courant en actuariat et dans le cadre de Solvabilité II ;

Ces dénominations peuvent désigner des quantités légèrement différentes lorsque la fonction de répartition F_X présente des discontinuités, mais elles coïncident lorsque F_X est continue. Dans ce mémoire, nous utilisons le terme ES et la définition intégrale ci-dessus, qui est la plus générale.

Remarque 4.3 (Interprétation intuitive). $\text{ES}_\alpha(X)$ est la moyenne des quantiles de X au-delà du niveau α , soit la « perte moyenne dans les $(1-\alpha)\%$ pires cas ». Lorsque F_X est continue, $\text{ES}_\alpha(X) = \mathbb{E}[X \mid X > \text{VaR}_\alpha(X)]$; c'est cette formulation conditionnelle qui justifie le nom « Conditional Value-at-Risk ».

Proposition 4.4 (Formule conditionnelle de l'ES). Si F_X est continue, alors

$$\text{ES}_\alpha(X) = \mathbb{E}[X \mid X > \text{VaR}_\alpha(X)].$$

Démonstration. Lorsque F_X est continue et strictement croissante, le changement de variables $u = F_X(x)$, soit $x = F_X^{-1}(u) = q_u(X)$, $du = f_X(x) dx$, donne :

$$\int_\alpha^1 q_u(X) du = \int_{q_\alpha(X)}^{+\infty} x f_X(x) dx = \mathbb{E}[X \cdot \mathbf{1}_{X > \text{VaR}_\alpha(X)}].$$

Donc

$$\text{ES}_\alpha(X) = \frac{\mathbb{E}[X \cdot \mathbf{1}_{X > \text{VaR}_\alpha(X)}]}{1 - \alpha} = \frac{\mathbb{E}[X \cdot \mathbf{1}_{X > \text{VaR}_\alpha(X)}]}{\mathbb{P}(X > \text{VaR}_\alpha(X))} = \mathbb{E}[X \mid X > \text{VaR}_\alpha(X)].$$

La dernière égalité utilise le fait que $\mathbb{P}(X > \text{VaR}_\alpha(X)) = 1 - F_X(\text{VaR}_\alpha(X)) = 1 - \alpha$ par continuité de F_X . $\square$

4.3 Calculs explicites

4.3.1 Loi normale

Si $X \sim \mathcal{N}(\mu, \sigma^2)$, alors

$$\text{ES}_\alpha(X) = \mu + \sigma \frac{\phi(\Phi^{-1}(\alpha))}{1 - \alpha},$$

où ϕ est la densité de la loi normale standard.

Exemple 4.5 (Fil rouge, ES sous loi normale). Pour $X_A \sim \mathcal{N}(0, 1)$ et $\alpha = 0,95$:

$$\text{ES}_{0,95}(X_A) = \frac{\phi(\Phi^{-1}(0,95))}{0,05} = \frac{\phi(1,645)}{0,05} \approx \frac{0,1031}{0,05} \approx 2,063.$$

Pour $X_\Pi \sim \mathcal{N}(0, 2)$:

$$\text{ES}_{0,95}(X_\Pi) = \sqrt{2} \times 2,063 \approx 2,917.$$

Vérifions la sous-additivité : $\text{ES}_{0,95}(X_A) + \text{ES}_{0,95}(X_B) = 2 \times 2,063 = 4,126 > 2,917$. $\checkmark$

4.3.2 Loi de Pareto

Pour X de loi de Pareto avec paramètre de queue $\xi > 1$ et paramètre d'échelle $x_m > 0$:

$$\text{ES}_\alpha(X) = \frac{\text{VaR}_\alpha(X)}{1 - 1/\xi} = \frac{x_m}{(1 - \alpha)^{1/\xi}(1 - 1/\xi)}.$$

Si $\xi \leq 1$, l'espérance de X est infinie et l'ES n'est pas définie (ou vaut $+\infty$). C'est une première illustration de la sensibilité des mesures de risque aux queues lourdes.

4.4 Cohérence de l'Expected Shortfall

Nous établissons maintenant la propriété théorique majeure de l'ES : elle est cohérente au sens de la définition 2.1. La preuve repose sur un résultat préliminaire de Rockafellar et Uryasev qui exprime l'ES comme la valeur d'un problème d'optimisation convexe.

Proposition 4.6 (Représentation variationnelle de l'ES, Rockafellar-Uryasev). *Pour toute variable aléatoire de perte X intégrable et tout $\alpha \in (0, 1)$,*

$$\text{ES}_\alpha(X) = \min_{v \in \mathbb{R}} \left\{ v + \frac{1}{1 - \alpha} \mathbb{E}[(X - v)^+] \right\},$$

où $(x)^+ = \max(x, 0)$. Le minimum est atteint en $v^* = \text{VaR}_\alpha(X)$.

Cette représentation remplace un problème sur les quantiles (non sous-additifs, cf. chapitre 3) par un problème d'optimisation convexe dont la valeur, elle, est sous-additive. C'est le point sur lequel repose la démonstration.

Théorème 4.7 (Cohérence de l'ES). *Pour tout $\alpha \in (0, 1)$, ES_α est une mesure de risque cohérente au sens de la définition 2.1.*

Démonstration. Vérifions chacun des quatre axiomes.

Monotonie. Si $X \leq Y$ p.s., alors $q_u(X) \leq q_u(Y)$ pour tout u (proposition B.2, point 4), donc par intégration $\text{ES}_\alpha(X) \leq \text{ES}_\alpha(Y)$.

Invariance par translation. Pour $c \in \mathbb{R}$, la proposition B.2 (point 3) donne $q_u(X + c) = q_u(X) + c$, donc

$$\text{ES}_\alpha(X + c) = \frac{1}{1 - \alpha} \int_\alpha^1 (q_u(X) + c) du = \text{ES}_\alpha(X) + c.$$

Homogénéité positive. Pour $\lambda > 0$, $q_u(\lambda X) = \lambda q_u(X)$ (proposition B.2, point 3), d'où $\text{ES}_\alpha(\lambda X) = \lambda \text{ES}_\alpha(X)$.

Sous-additivité. C'est le point délicat. Utilisons la représentation variationnelle de la proposition 4.6. Soient v_X et v_Y les minimiseurs respectifs pour X et Y . Alors

$$\text{ES}_\alpha(X + Y) = \min_{v \in \mathbb{R}} \left\{ v + \frac{\mathbb{E}[(X + Y - v)^+]}{1 - \alpha} \right\} \leq v_X + v_Y + \frac{\mathbb{E}[(X + Y - v_X - v_Y)^+]}{1 - \alpha},$$

en choisissant $v = v_X + v_Y$. Or, par sous-additivité de la fonction $(\cdot)^+$,

$$(X + Y - v_X - v_Y)^+ = ((X - v_X) + (Y - v_Y))^+ \leq (X - v_X)^+ + (Y - v_Y)^+.$$

On en déduit

$$\begin{aligned} \text{ES}_\alpha(X + Y) &\leq v_X + v_Y + \frac{\mathbb{E}[(X - v_X)^+] + \mathbb{E}[(Y - v_Y)^+]}{1 - \alpha} \\ &= \left[v_X + \frac{\mathbb{E}[(X - v_X)^+]}{1 - \alpha} \right] + \left[v_Y + \frac{\mathbb{E}[(Y - v_Y)^+]}{1 - \alpha} \right] \\ &= \text{ES}_\alpha(X) + \text{ES}_\alpha(Y). \end{aligned}$$

□

Remarque 4.8 (Mesure cohérente, donc spectrale). L'ES s'écrit comme moyenne pondérée des quantiles avec poids $\phi(u) = \frac{1}{1 - \alpha} \mathbf{1}_{u > \alpha}$: c'est donc une mesure spectrale au sens de la définition 2.12. La fonction ϕ est positive, croissante et normalisée, et concentre tout le poids sur les quantiles supérieurs à α . L'ES est ainsi l'instance la plus simple de mesure spectrale, paramétrée par un unique seuil de queue.

Remarque 4.9 (Allocation Euler de l'ES). Le théorème 2.14 de l'allocation par Euler s'applique à l'ES, qui est positivement homogène. Sous des hypothèses de continuité de la loi de X_Π , on montre que $\rho_i^{\text{Euler}} = \mathbb{E}[X_i \mid X_\Pi > \text{VaR}_\alpha(X_\Pi)]$. Sous loi gaussienne, la formule explicite obtenue dans l'exemple 2.15 pour la mesure de volatilité se transpose directement à l'ES : les coefficients d'allocation $(\sigma_i^2 + \rho_{ij}\sigma_i\sigma_j)/\sigma_\Pi^2$ sont identiques, seul le facteur multiplicatif change (de λ à $\varphi(\Phi^{-1}(\alpha))/(1 - \alpha)$). Autrement dit, toutes les mesures cohérentes proportionnelles à σ sous loi elliptique partagent la même structure d'allocation.

4.5 ES et régulation : le passage de Bâle II à Bâle IV

Le Comité de Bâle sur le contrôle bancaire a pendant longtemps utilisé la VaR à 99% comme mesure de risque de marché (Bâle II, puis Bâle III). Les insuffisances mises en lumière par la crise de 2008 ont conduit à une révision en profondeur. La révision fondamentale du portefeuille de négociation (*Fundamental Review of the Trading Book*, FRTB), intégrée dans Bâle IV, remplace la VaR à 99% par l'ES à 97,5% pour le calcul des exigences en fonds propres au titre du risque de marché. Ce choix est motivé par :

- la supériorité théorique de l'ES (cohérence, prise en compte des pertes extrêmes) ;
- le fait que l'ES à 97,5% et la VaR à 99% donnent des valeurs comparables sous loi normale, facilitant la transition ;
- une meilleure capture du risque de queue (*tail risk*).

Nous reviendrons sur les difficultés de backtesting de l'ES au chapitre 5.

5 Validation empirique : backtesting et stress testing

Les chapitres précédents ont développé la théorie des mesures de risque. Ce chapitre la confronte aux données. Il s'agit, sur le portefeuille empirique introduit au chapitre 1, de répondre à trois questions : comment estime-t-on en pratique la VaR et l'ES, comment vérifie-t-on *a posteriori* qu'un modèle est bien calibré, et comment se comporte-t-il dans des scénarios extrêmes qui sortent de la modélisation statistique habituelle ? Les outils utilisés sont, dans l'ordre : estimation par trois méthodes (historique, paramétrique gaussienne, Monte Carlo Student), backtesting de la VaR (tests de Kupiec [11] et de Christoffersen [12]) et sensibilité à la taille de fenêtre, backtesting de l'ES via la statistique d'Acerbi-Szekely, et enfin *stress test* historique sur les crises de 2008 et de 2020. L'ensemble des scripts Python est reporté à l'annexe A ; le corps du chapitre ne présente que les résultats et leur interprétation.

5.1 Méthodologie et estimation

Préparation des données. Les cours de clôture ajustés des quatre actifs sont téléchargés via la bibliothèque `yfinance` (annexe A.1). Sur la période du 3 janvier 2008 au 30 décembre 2025, on dispose de $T = 4482$ rendements quotidiens par actif après alignement des calendriers de cotation. La perte du portefeuille équilibré au jour t est définie par

$$X_t = - \sum_{i=1}^4 w_i r_{i,t}, \quad w_i = \frac{1}{4},$$

où $r_{i,t}$ est le log-rendement de l'actif i au jour t . Cette convention place $X_t > 0$ en cas de perte et permet d'utiliser directement les définitions des chapitres précédents.

Trois méthodes d'estimation. Pour chaque jour t , la VaR et l'ES à l'horizon du lendemain sont estimées sur la fenêtre des 250 derniers jours ouvrés (un an d'historique, conformément à la convention de Bâle pour le backtesting réglementaire) selon trois approches :

- **Historique** : $\widehat{\text{VaR}}_\alpha^{\text{hist}}$ est le quantile empirique d'ordre α des pertes observées sur la fenêtre, et $\widehat{\text{ES}}_\alpha^{\text{hist}}$ la moyenne des pertes au-delà.
- **Paramétrique gaussienne** : on suppose $X_t \sim \mathcal{N}(\hat{\mu}, \hat{\sigma}^2)$ sur la fenêtre, ce qui donne $\widehat{\text{VaR}}_\alpha = \hat{\mu} + \hat{\sigma} \Phi^{-1}(\alpha)$ et $\widehat{\text{ES}}_\alpha = \hat{\mu} + \hat{\sigma} \phi(\Phi^{-1}(\alpha)) / (1 - \alpha)$ (formules du chapitre 3).
- **Monte Carlo Student** : on ajuste une loi de Student par maximum de vraisemblance sur la fenêtre, on simule 10^5 tirages, puis on calcule la VaR et l'ES empiriques sur ces tirages. Le choix de la Student vise à capter la kurtosis élevée observée au tableau 1.

Résultats au 30 décembre 2025. Le tableau 2 donne les estimations à la dernière date de l'échantillon.

Trois points ressortent. D'abord, sur le quantile (VaR), les trois méthodes donnent des valeurs proches : sur cette fenêtre récente (année 2025), relativement calme, la queue empirique n'est pas trop éloignée d'une queue gaussienne. En revanche, dès qu'on passe à la *moyenne de queue* (ES), l'écart se creuse nettement : 3,47% pour l'historique contre 2,23% pour le paramétrique à $\alpha = 0,975$, soit un écart de plus de 50%. On retrouve le point du chapitre 3 : deux distributions peuvent partager le même quantile mais avoir des

Méthode	$\alpha = 0,95$		$\alpha = 0,975$	
	VaR	ES	VaR	ES
Historique	1,33%	2,57%	1,89%	3,47%
Paramétrique gaussienne	1,55%	1,96%	1,86%	2,23%
Monte Carlo Student	1,21%	2,12%	1,70%	2,82%

TABLE 2 – Estimations de la VaR et de l'ES sur le portefeuille empirique au 30 décembre 2025, fenêtre glissante de 250 jours. Valeurs en pourcentage de la valeur du portefeuille.

moyennes de queue très différentes. Enfin, le Monte Carlo Student se positionne entre les deux pour la VaR mais reste plus prudent que le gaussien pour l'ES, comme attendu.

Évolution dans le temps. La figure 1 représente la VaR à 95% estimée par les trois méthodes sur l'ensemble de la période. On distingue clairement deux périodes de forte hausse du risque : la crise de 2008-2009 et le choc de mars 2020. En période calme, les trois méthodes donnent des résultats proches. En période de stress, la VaR gaussienne est la plus élevée, la méthode historique donne une estimation intermédiaire, tandis que la méthode Monte Carlo avec loi de Student reste plus basse.

Ce dernier point peut sembler surprenant, car une loi de Student possède des queues plus épaisses. Il s'explique par l'estimation des paramètres : sur certaines fenêtres, la loi de Student ajuste une échelle plus faible que l'écart-type empirique. À 95%, cela peut conduire à une VaR plus faible. Pour des niveaux plus extrêmes, comme 99%, l'effet des queues épaisses deviendrait plus important.




FIGURE 1 – VaR à 95% estimée sur fenêtre glissante de 250 jours, par méthode (historique, paramétrique gaussienne, Monte Carlo Student). Portefeuille empirique 2008-2025.

5.2 Backtesting de la VaR

Le backtesting consiste à compter, sur l'ensemble de la période, les *exceptions*, c'est-à-dire les jours où la perte effective dépasse la VaR estimée la veille. Sous le modèle correct, la probabilité d'exception est $1 - \alpha$ et le nombre d'exceptions N suit une loi binomiale de

paramètres $(n_{\text{test}}, 1 - \alpha)$, où $n_{\text{test}} = T - 250 = 4232$ est le nombre de jours testés (les 250 premiers servent à constituer la première fenêtre d'estimation).

Comptage des exceptions. Sur les 4232 jours testés, le nombre attendu d'exceptions à 95% est $0,05 \times 4232 \approx 212$. Le tableau 3 donne les comptes observés.

Méthode	N	$\hat{p}$
Historique	234	5,53%
Paramétrique gaussienne	235	5,55%
Monte Carlo Student	263	6,21%
<i>Attendu sous H_0</i>	212	5,00%

TABLE 3 – Nombre d'exceptions observées sur les 4232 jours de backtesting, $\alpha = 0,95$.

Les méthodes historique et paramétrique sont très proches (234 et 235 exceptions, soit environ 5,5%). Le Monte Carlo Student, en revanche, génère sensiblement plus d'exceptions (263, soit 6,21%). Ce résultat peut paraître contre-intuitif : on attendrait du Student un comportement plus prudent, donc *moins* d'exceptions. L'explication tient au mécanisme d'estimation : sur fenêtre glissante, l'ajustement par maximum de vraisemblance peut produire des degrés de liberté très bas en période de stress, ce qui pousse les VaR estimées vers des valeurs très élevées en queue, mais pas suffisamment pour compenser, sur l'ensemble de la période, le bruit d'estimation introduit par le double passage *ajustement + simulation*.

Définition 5.1 (Statistique de Kupiec). Soit N le nombre d'exceptions observées sur n_{test} jours de backtesting, et $\hat{p} = N/n_{\text{test}}$ le taux d'exception empirique. Sous l'hypothèse nulle de couverture inconditionnelle $H_0 : p = 1 - \alpha$, la statistique du rapport de vraisemblance de Kupiec est

$$\text{LR}_{\text{uc}} = -2 \ln \left[\frac{\alpha^{n_{\text{test}}-N} (1 - \alpha)^N}{(1 - \hat{p})^{n_{\text{test}}-N} \hat{p}^N} \right].$$

Sous H_0 , LR_{uc} converge en loi vers une $\chi^2(1)$ par le théorème de Wilks. On rejette H_0 au seuil β si $\text{LR}_{\text{uc}} > \chi^2_{1-\beta}(1)$ (par exemple $\chi^2_{0,95}(1) \approx 3,84$ au seuil de 5%).

Remarque 5.2. Le numérateur de LR_{uc} est la vraisemblance des exceptions sous H_0 (probabilité $1 - \alpha$), le dénominateur la vraisemblance maximisée (paramètre $\hat{p}$). Une grande valeur de LR_{uc} signale que le taux empirique $\hat{p}$ s'écarte significativement du taux théorique $1 - \alpha$.

Test de Kupiec. La statistique du rapport de vraisemblance de Kupiec, sous l'hypothèse nulle $H_0 : p = 1 - \alpha$, suit asymptotiquement une loi $\chi^2(1)$. Le tableau 4 donne les statistiques et p -valeurs.

Le verdict de Kupiec est inattendu : ce sont les méthodes les plus simples (historique et paramétrique gaussienne) qui passent le test au seuil usuel de 5%, tandis que le Monte Carlo Student, plus sophistiqué en théorie, est rejeté. Autrement dit, la méthode la plus sophistiquée n'est pas la mieux calibrée ici : sur cette période, les estimateurs simples passent le test de Kupiec, pas le Monte Carlo Student.

Méthode	LR _{uc}	<i>p</i> -valeur	Conclusion
Historique	2,42	0,120	Non rejet
Paramétrique gaussienne	2,63	0,105	Non rejet
Monte Carlo Student	12,24	0,0005	Rejet à 1%

TABLE 4 – Test de Kupiec, $\alpha = 0,95$. Seul le Monte Carlo Student est rejeté.

Définition 5.3 (Statistique de Christoffersen). Soit $(\mathbf{1}_t)_{t=1,\dots,n_{\text{test}}}$ la suite des indicateurs d'exception. On note n_{ij} le nombre de transitions de l'état i vers l'état j dans cette suite ($i, j \in \{0, 1\}$). On pose

$$\hat{\pi}_{01} = \frac{n_{01}}{n_{00} + n_{01}}, \quad \hat{\pi}_{11} = \frac{n_{11}}{n_{10} + n_{11}}, \quad \hat{\pi} = \frac{n_{01} + n_{11}}{n_{00} + n_{01} + n_{10} + n_{11}}.$$

La statistique du rapport de vraisemblance d'*indépendance* est

$$\text{LR}_{\text{ind}} = -2 \ln \left[\frac{(1 - \hat{\pi})^{n_{00} + n_{10}} \hat{\pi}^{n_{01} + n_{11}}}{(1 - \hat{\pi}_{01})^{n_{00}} \hat{\pi}_{01}^{n_{01}} (1 - \hat{\pi}_{11})^{n_{10}} \hat{\pi}_{11}^{n_{11}}} \right],$$

qui suit asymptotiquement une $\chi^2(1)$. La statistique de Christoffersen, qui teste conjointement la couverture inconditionnelle et l'indépendance temporelle, est alors

$$\text{LR}_{\text{cc}} = \text{LR}_{\text{uc}} + \text{LR}_{\text{ind}} \xrightarrow{\mathcal{L}} \chi^2(2).$$

Test de Christoffersen. Le test de Kupiec ne contrôle que le *taux* d'exception. Le test de Christoffersen ajoute le contrôle de l'*indépendance temporelle* : sous le modèle correct, les exceptions doivent être éparpillées et non groupées en *clusters*. Or, sur notre période, les exceptions se concentrent nettement en 2008-2009 et en mars 2020. La figure 2 les visualise sur un calendrier.




FIGURE 2 – Exceptions de la VaR historique à 95% sur le portefeuille empirique. Chaque trait vertical représente un jour d'exception. On distingue clairement les regroupements de fin 2008 (faillite Lehman) et de mars 2020 (COVID-19).

Le tableau 5 donne les résultats du test conjoint à 2 degrés de liberté.

Méthode	LR _{cc}	<i>p</i> -valeur	Conclusion
Historique	23,58	$< 10^{-4}$	Rejet
Paramétrique gaussienne	25,56	$< 10^{-4}$	Rejet
Monte Carlo Student	33,10	$< 10^{-4}$	Rejet

TABLE 5 – Test de Christoffersen, $\alpha = 0,95$. **Toutes les méthodes sont rejetées.**

Aucune des trois méthodes ne passe Christoffersen. Cela ne veut pas dire que les méthodes sont mauvaises : pour deux d'entre elles, le nombre total d'exceptions restait acceptable. Cela veut dire que l'hypothèse de stationnarité des pertes, centrale pour le backtesting, est violée. Pour la respecter, il faudrait recourir à des modèles à volatilité variable (GARCH, par exemple) [14], ce qui dépasse le cadre de ce mémoire.

5.3 Sensibilité du backtesting à la taille de fenêtre

Le choix d'une fenêtre glissante de 250 jours suit la convention de Bâle, mais il reste arbitraire. Une fenêtre plus courte réagit rapidement aux changements de régime de volatilité, au prix d'un bruit d'estimation accru ; une fenêtre plus longue lisse l'estimation mais répond avec retard. Nous quantifions cet arbitrage en rejouant le backtesting de la VaR à 95 % pour quatre tailles de fenêtre.

Fenêtre	Historique	Paramétrique	Lecture
60 jours	6,81 %	6,17 %	sur-réactif
125 jours	5,97 %	5,81 %	léger excès
250 jours	5,53 %	5,55 %	référence ($\approx 5\%$)
500 jours	4,90 %	4,87 %	sous-couverture

TABLE 6 – Taux d'exception observés à $\alpha = 0,95$ (cible théorique 5 %), portefeuille empirique 2008–2025. La fenêtre de 60 jours sur-réagit, la fenêtre de 500 jours sous-couvre ; 250 jours est la plus proche de la cible.

Interprétation. L'arbitrage réactivité/stabilité est lui-même une manifestation du problème de fond : aucune fenêtre ne résout la non-stationnarité. La fenêtre courte voit les ruptures mais sur-réagit au bruit ; la fenêtre longue est stable mais aveugle. Le choix de 250 jours est un compromis raisonnable, non un optimum.

5.4 Backtesting de l'Expected Shortfall

Pourquoi c'est plus difficile. Contrairement à la VaR, l'ES n'est pas *élicitable* au sens de Gneiting [8] : il n'existe pas de fonction de score $S(\hat{r}, x)$ strictement consistante qui prenne pour seul argument la prévision $\hat{r}$ de l'ES et la réalisation x de la perte. Concrètement, on ne peut pas backtester l'ES en comparant directement chaque prévision à chaque réalisation comme on le fait pour la VaR. Ce résultat a longtemps servi d'argument pour préférer la VaR à l'ES dans la réglementation. Fissler et Ziegel [9] ont montré que le couple (VaR, ES) est en revanche *conjointement élicitable*, ce qui ouvre la voie à des tests basés sur les deux quantités.

Test d'Acerbi-Szekely. Acerbi et Szekely [7] proposent plusieurs statistiques de backtesting pour l'ES. La plus utilisée est

$$Z_2 = \frac{1}{n_{\text{test}}(1 - \alpha)} \sum_t \frac{X_t \mathbf{1}_{X_t > \widehat{\text{VaR}}_\alpha^{(t-1)}}}{\widehat{\text{ES}}_\alpha^{(t-1)}} - 1.$$

Sous le modèle correct, $\mathbb{E}[Z_2] = 0$. Un Z_2 positif signale que les pertes en queue sont *plus sévères* que prévues par l'ES estimée (donc que l'ES sous-estime le risque) ; un Z_2 négatif l'inverse. La p -valeur est obtenue par bootstrap paramétrique. Les résultats sur notre portefeuille à $\alpha = 0,975$ sont reportés au tableau 7.

Méthode	Z_2 observé	p-valeur bootstrap	Conclusion
Historique	+0,358	0,995	Non-rejet
Paramétrique gaussienne	+0,794	0,896	Non-rejet
Monte Carlo Student	+0,493	0,918	Non-rejet

TABLE 7 – Backtesting de l'Expected Shortfall à $\alpha = 97,5\%$ par la statistique d'Acerbi-Szekely.

Ce résultat se lit avec prudence. Les trois statistiques Z_2 sont toutes positives, mais modestes (de 0,36 à 0,79) : prises telles quelles, elles indiquent une sous-estimation des pertes de queue, plus marquée pour la paramétrique gaussienne, comme le laissait prévoir le diagnostic du chapitre 3. Pourtant, les p -valeurs bootstrap sont toutes élevées et ne rejettent rien. C'est là toute la difficulté de backtester l'ES. La statistique pointe un problème que le test n'a pas la puissance de confirmer : le bootstrap resimule sous une Student ajustée sur toutes les pertes, crises comprises, et génère donc des Z_2 du même ordre, contre lesquels les valeurs observées ne ressortent pas. Le test reste valide, mais dit peu de chose sur une période aussi chargée. On retrouve l'asymétrie déjà annoncée : Kupiec tranche nettement pour la VaR, l'ES ne laisse qu'un signal qualitatif.

5.5 Stress testing : les crises de 2008 et 2020

Logique. La *stress test* ne cherche pas à valider un modèle statistique, mais à explorer ce qu'il advient du portefeuille sous des scénarios extrêmes. Plutôt que d'inventer des chocs hypothétiques, nous appliquons au portefeuille actuel les chocs *historiquement observés* lors des deux crises majeures de notre période.

Crise de 2008 : la semaine de Lehman. Le tableau 8 récapitule les rendements observés entre le 6 et le 10 octobre 2008 sur les quatre actifs. La perte cumulée du portefeuille équilibré sur la semaine atteint $-16,16\%$.

Date	S&P 500	CAC 40	Apple	TotalEnergies
06/10/2008	-3,93%	-9,47%	+1,10%	-9,33%
07/10/2008	-5,91%	+0,54%	-9,60%	+2,95%
08/10/2008	-1,14%	-6,51%	+0,70%	-7,43%
09/10/2008	-7,92%	-1,56%	-1,18%	-3,30%
10/10/2008	-1,18%	-8,05%	+8,69%	-8,00%
<i>Cumul portefeuille équilibré : -16,16%</i>				
<i>Pire journée : 6 octobre 2008, perte = 5,41%</i>				

TABLE 8 – Rendements log quotidiens observés du 6 au 10 octobre 2008.

Choc COVID : mars 2020. La séquence du 9 au 13 mars 2020 (tableau 9) est, en valeur absolue, encore plus violente sur les actifs individuels : TotalEnergies perd $-18,16\%$ sur la seule séance du 9 mars, et le portefeuille subit $-12,38\%$ en une journée le 12 mars. La perte cumulée sur la semaine est très proche de celle de 2008 ($-16,23\%$), mais concentrée sur deux séances cataclysmiques plutôt qu'étalée.

Date	S&P 500	CAC 40	Apple	TotalEnergies
09/03/2020	$-7,90\%$	$-8,76\%$	$-8,24\%$	$-18,16\%$
10/03/2020	$+4,82\%$	$-1,53\%$	$+6,95\%$	$+1,71\%$
11/03/2020	$-5,01\%$	$-0,57\%$	$-3,53\%$	$-1,76\%$
12/03/2020	$-9,99\%$	$-13,10\%$	$-10,40\%$	$-16,03\%$
13/03/2020	$+8,88\%$	$+1,82\%$	$+11,32\%$	$-1,35\%$
<i>Cumul portefeuille équipondéré : $-16,23\%$</i>				
<i>Pire journée : 12 mars 2020, perte = $12,38\%$</i>				

TABLE 9 – Rendements log quotidiens observés du 9 au 13 mars 2020.

Comparaison avec la VaR/ES nominales. Le tableau 10 compare les pertes effectives lors des deux crises aux estimations VaR/ES qui auraient été calculées la veille de chaque crise par chacune des trois méthodes (chiffres issus du script de l'annexe A).

	Pire journée 2008 (06/10/2008)	Pire journée 2020 (12/03/2020)
Perte effective sur le portefeuille	5,41%	12,38%
$\widehat{\text{VaR}}_{0,975}^{\text{hist}}$ veille	4,03%	2,73%
$\widehat{\text{ES}}_{0,975}^{\text{hist}}$ veille	5,61%	4,47%
$\widehat{\text{VaR}}_{0,975}^{\text{para}}$ veille	3,61%	2,55%
$\widehat{\text{ES}}_{0,975}^{\text{para}}$ veille	4,26%	3,04%
$\widehat{\text{VaR}}_{0,975}^{\text{Student}}$ veille	3,54%	2,34%
$\widehat{\text{ES}}_{0,975}^{\text{Student}}$ veille	5,29%	4,49%

TABLE 10 – Pertes effectives lors des pires journées des crises de 2008 et 2020, comparées aux mesures de risque estimées la veille (fenêtre glissante de 250 jours, tronquée à 189 jours pour octobre 2008 du fait de l'horizon de l'échantillon). Toutes les valeurs sont en pourcentage de la valeur du portefeuille.

La comparaison des deux crises nuance l'idée reçue selon laquelle les mesures de risque échoueraient toujours face à un événement extrême.

En 2008, l'ES historique de la veille (5,61 %) couvre la perte réalisée de 5,41 %, et l'ES Monte Carlo Student (5,29 %) la couvre presque ; seule la gaussienne (4,26 %) est nettement dépassée, d'un facteur 1,3. La raison tient à la fenêtre d'estimation : de janvier à octobre 2008, le marché avait déjà encaissé plusieurs mois de turbulences (chute de Bear Stearns en mars, dégradations en série des produits structurés), si bien que les estimateurs, calés sur les 189 jours précédents, partaient déjà d'une volatilité élevée.

Mars 2020 donne l'image inverse. La perte réalisée de 12,38 % vaut 2,8 fois l'ES historique et l'ES Monte Carlo Student, et 4,1 fois la gaussienne : aucune méthode n'en approche. Cette fois, les 250 jours précédant le 9 mars étaient dominés par une année 2019 très calme, et le choc est arrivé sans le moindre signal avant-coureur dans la volatilité.

On voit là la limite des mesures calibrées sur le passé récent : elles tiennent tant que la fenêtre contient déjà du stress, et cèdent dès qu'un régime bascule. Ce n'est pas un défaut des estimateurs : ils extrapolent la distribution récente, et c'est tout ce qu'on leur demande. Mais une extrapolation ne dit rien d'un choc qui n'est pas dans la fenêtre. C'est précisément ce que le stress test ajoute au backtesting : il ne valide pas le modèle, il montre où il devient aveugle.

5.6 Allocation d'Euler : décomposition du risque par actif

Pour l'ES, positivement homogène, le théorème d'Euler fournit une décomposition additive exacte des contributions par actif :

$$\rho_i = w_i \mathbb{E}[X_i \mid X_\Pi > \text{VaR}_\alpha(X_\Pi)], \quad \sum_i \rho_i = \text{ES}_\alpha(X_\Pi). \quad (1)$$

Nous calculons ces contributions sur quatre sous-périodes contrastées, pour observer le déplacement de la concentration du risque.

Période	ES totale	S&P 500	CAC 40	Apple	TotalEnergies
Calme 2017	1,02 %	17 %	21 %	36 %	25 %
Crise 2008–09	6,06 %	28 %	22 %	26 %	24 %
COVID 2020	10,00 %	23 %	21 %	22 %	35 %
Récent 2023–25	1,93 %	19 %	22 %	30 %	29 %

TABLE 11 – Contributions d'Euler à l'ES à 95 %. L'ES totale du portefeuille passe de $\approx 1\%$ en période calme à 10 % pendant la crise COVID (facteur 10). TotalEnergies y bondit à 35 % du risque (krach pétrolier de mars 2020), contre 25 % en période calme. Contributions arrondies au point de pourcentage.

Interprétation. La diversification apparente d'un portefeuille équi pondéré est trompeuse : en crise, le risque se reconcentre sur l'actif le plus touché. C'est un argument supplémentaire pour préférer l'ES en gestion : étant cohérente et positivement homogène, elle autorise cette décomposition additive exacte (1), ce que la VaR ne permet pas proprement faute de sous-additivité.

5.7 Synthèse

L'analyse empirique dégage quelques enseignements. Le premier est que le résultat dépend fortement de la méthode : historique, paramétrique et Student ne réagissent pas de la même façon aux pics de volatilité. La taille de la fenêtre compte tout autant. Une fenêtre courte réagit vite, au prix d'estimations instables ; une fenêtre longue est stable, mais répond avec retard.

Côté VaR, les méthodes historique et paramétrique passent Kupiec, avec une couverture à 95 % acceptable. Christoffersen, lui, rejette l'indépendance des exceptions : elles se

massent en 2008-2009 et en mars 2020. Le Monte Carlo Student produit trop d'exceptions et apparaît moins bien calibré sur cet échantillon.

L'ES à 97,5 % donne un verdict plus ambigu. Les statistiques d'Acerbi-Szekely sont positives, ce qui pointe une sous-estimation des pertes de queue ; mais les p-valeurs bootstrap, élevées, ne permettent pas de rejeter les prévisions. C'est précisément ce qui rend l'ES difficile à valider sur données, alors qu'elle est mieux fondée en théorie.

Les stress tests vont dans le même sens. Sur fenêtre glissante, une mesure peut être prise en défaut par une rupture brutale de régime : 2008 et 2020 affichent des pertes hebdomadaires proches, mais 2020 les concentre sur deux séances.

Reste l'allocation d'Euler, qui dépasse le risque agrégé en donnant la part de chaque actif. Cette part change beaucoup selon la période : elle dépend de la volatilité de l'actif, mais aussi de la façon dont il se comporte quand le portefeuille subit ses pires pertes. L'ES ne se limite donc pas à un chiffre global ; elle se décompose, et c'est ce qui en fait un outil de gestion.

6 Optimisation de portefeuille par minimisation de la CVaR

Pour clore le mémoire, une question pratique : comment choisir les poids d'un portefeuille pour minimiser son risque ? On compare la minimisation de l'Expected Shortfall (CVaR) à deux références, le portefeuille équilibré et le portefeuille de variance minimale de Markowitz.

6.1 Le problème de minimisation de la CVaR

Rockafellar et Uryasev [3, 4] ont montré que minimiser l'ES (CVaR) sur un portefeuille se reformule en problème d'optimisation linéaire, donc parfaitement traitable numériquement.

Théorème 6.1 (Rockafellar-Uryasev). *Soit X_w la perte d'un portefeuille de poids w . Alors*

$$\text{ES}_\alpha(X_w) = \min_{v \in \mathbb{R}} \left\{ v + \frac{1}{(1-\alpha)T} \sum_{t=1}^T (X_w^{(t)} - v)^+ \right\},$$

et $\min_w \text{ES}_\alpha(X_w)$ est un problème convexe (linéaire si X_w est linéaire en w).

Idée. On part de la proposition 4.6, $\text{ES}_\alpha(X) = \min_v \{v + \frac{1}{1-\alpha} \mathbb{E}[(X - v)^+]\}$, et on remplace l'espérance par la moyenne empirique sur T scénarios. Le problème joint en (w, v) est convexe en w (car X_w est linéaire et $(\cdot)^+$ convexe) et en v . $\square$

L'intérêt est immédiat : on minimise le risque d'un portefeuille avec des solveurs convexes standard. Là où Markowitz minimisait la variance, on minimise l'ES, à complexité comparable.

6.2 Application au portefeuille

Concrètement, on minimise l'ES par un *programme linéaire*. Avec r_t le vecteur des rendements au jour t et w les poids,

$$\min_{w, v, u} v + \frac{1}{(1-\alpha)T} \sum_{t=1}^T u_t \quad \text{s.c.} \quad u_t \geq -r_t^\top w - v, \quad u_t \geq 0, \quad \sum_i w_i = 1, \quad w_i \geq 0, \quad (2)$$

donne à l'optimum $v^* = \text{VaR}_\alpha$ et une valeur égale à ES_α . On compare le portefeuille équilibré et le minimum-CVaR, calibrés sur 2008–2018 puis évalués hors échantillon sur 2019–2025.

L'optimiseur produit la composition suivante : S&P 500 52,7 %, CAC 40 10,1 %, Apple 8,5 %, TotalEnergies 28,7 %. Il surpondère nettement l'indice américain et allège les deux valeurs individuelles à queue plus lourde, Apple et TotalEnergies.

Comme point de comparaison, on calcule aussi le portefeuille de *variance minimale* de Markowitz, qui minimise $w^\top \Sigma w$ sous les mêmes contraintes (poids positifs, somme égale à un). C'est le réflexe historique de la gestion quantitative, et c'est déjà une optimisation sous mesure de risque : la variance n'est rien d'autre que la « mesure de volatilité » du chapitre 2. Elle a toutefois le défaut qu'on lui connaît. Prise seule, elle n'est pas cohérente, et surtout elle pénalise un gros gain exactement comme une grosse perte. Sa composition ici : S&P 500 61,2 %, CAC 40 9,4 %, Apple 5,1 %, TotalEnergies 24,3 %, encore plus concentrée sur l'indice le moins volatil. Le verdict hors échantillon colle à ce que chaque

Portefeuille	Vol.	VaR 95 %	ES 95 %	Pire perte
Équipondéré	1,21 %	1,62 %	2,96 %	12,38 %
Min-variance	1,16 %	1,60 %	2,95 %	12,30 %
Min-CVaR 95 %	1,19 %	1,62 %	2,90 %	12,07 %

TABLE 12 – Risque *out-of-sample* (2019–2025). La variance minimale minimise la volatilité ; le minimum-CVaR minimise l'ES et la pire perte.

Optimisation CVaR (Rockafellar-Uryasev) : équipondéré vs variance minimale vs min-CVaR




FIGURE 3 – À gauche, les compositions optimales ; à droite, le risque *out-of-sample* : le minimum-CVaR réduit la queue.

méthode optimise. La variance minimale décroche la plus faible volatilité (1,16 %), et c'est bien son but. Mais c'est le minimum-CVaR qui obtient la plus faible ES et la pire perte la plus contenue, parce que lui vise la queue gauche, pas la dispersion symétrique. L'écart reste modeste sur ces données, et c'est attendu : sous loi proche de l'elliptique, variance, VaR et ES classent les portefeuilles presque pareil. Ils ne divergeraient nettement que sur des actifs très asymétriques.

On retrouve ici l'autre face du compromis rigueur / validabilité. Les propriétés qui gênaient le backtesting, convexité et cohérence, sont justement celles qui rendent l'ES optimisable par programme linéaire, là où la VaR donnerait un problème non convexe. Selon qu'on cherche à valider une mesure ou à optimiser un portefeuille, la même ES devient un handicap ou un atout.

Conclusion

Bilan

Ce mémoire a comparé les principales mesures de risque utilisées en finance et en actuariat : la Value-at-Risk, l'Expected Shortfall, et le cadre des mesures cohérentes qui permet de les juger. À chaque étape, la théorie a été confrontée aux données.

Nous avons montré que la VaR, malgré son omniprésence pratique, souffre d'une limite mathématique fondamentale : elle n'est pas sous-additive en général. Cela signifie qu'elle peut pénaliser la diversification, ce qui contredit l'intuition économique de base. Concrètement, une banque qui pilote son capital avec la VaR peut être tentée de découper une position risquée en sous-positions pour afficher un risque agrégé plus faible.

L'Expected Shortfall corrige cette lacune. Nous avons démontré rigoureusement qu'elle est sous-additive (via la représentation variationnelle de Rockafellar-Uryasev) et qu'elle satisfait tous les axiomes de cohérence. Elle prend en compte l'ampleur des pertes extrêmes, là où la VaR se contente d'identifier un seuil.

Le cadre axiomatique d'Artzner, Delbaen, Eber et Heath donne un fondement mathématique solide à la notion de « bonne » mesure de risque. Le théorème de représentation des mesures cohérentes révèle leur structure profonde : une mesure cohérente est toujours un pire cas sur un ensemble de scénarios probabilistes, ce qui lui confère une interprétation robuste.

Le backtesting et le stress testing font apparaître un renversement : la VaR, pourtant déficiente en théorie, se laisse valider sans peine, alors que l'ES y résiste. La mesure la mieux fondée n'est donc pas la plus simple à contrôler sur données.

Retour sur la problématique

Notre question centrale était : quelles propriétés doit satisfaire une bonne mesure de risque, et les outils disponibles y répondent-ils ?

En théorie, le bon candidat est clair : sous-additivité, monotonie, invariance par translation, homogénéité autant d'axiomes que l'ES vérifie. Mais en pratique comptent aussi la facilité de calcul, de communication et de validation, ainsi que la stabilité statistique ; sur ces points, la VaR garde l'avantage. La VaR reste supérieure en simplicité opérationnelle et en backtesting, mais l'ES est supérieure comme mesure de risque théoriquement cohérente et comme outil d'optimisation.

Ouvertures

Plusieurs directions naturelles prolongent ce mémoire. Les mesures de risque dynamiques permettent de raisonner sur des horizons longs, en prenant en compte l'évolution de l'information. La théorie des valeurs extrêmes offre des outils statistiques adaptés à l'estimation des quantiles extrêmes. L'optimisation de portefeuille sous contrainte de CVaR, rendue tractable par les résultats de Rockafellar et Uryasev, est une voie prometteuse pour la gestion active des risques.

A Code Python

Le code Python complet utilisé pour produire les résultats empiriques du chapitre 5 est disponible sur le dépôt GitHub suivant :

<https://github.com/mezaouifinance/memoire-mesures-de-risque>

Le dépôt contient le script principal `annexe_code_complet.py`, la liste des dépendances nécessaires et les données utilisées pour reproduire les résultats numériques du mémoire.

Les principales bibliothèques utilisées sont :

`numpy, pandas, scipy, matplotlib, yfinance.`

Les données portent sur quatre actifs :

`^GSPC (S&P500), ^FCHI (CAC40), AAPL, TTE.PA.`

Les rendements sont calculés en log-rendements à partir des prix ajustés, et les pertes sont définies par :

$$X_t = -r_t.$$

Les paramètres principaux utilisés dans le chapitre empirique sont :

fenêtre glissante = 250 jours, $\alpha_{\text{VaR}} = 95\%$, $\alpha_{\text{ES}} = 97,5\%$.

Le script permet de reproduire les estimations de VaR et d'Expected Shortfall, les tests de backtesting, les stress tests historiques, l'analyse de sensibilité à la taille de fenêtre, ainsi que les extensions numériques relatives à l'optimisation CVaR et à l'allocation d'Euler.

Les sorties numériques principales sont reportées directement dans le chapitre 5.

A.1 Estimateurs de la VaR et de l'ES

```
1 import numpy as np
2 from scipy import stats, optimize
3
4 def var_es_historique(losses, alpha):
5     """VaR et ES par quantile empirique sur la fenetre."""
6     losses = np.asarray(losses)
7     var = np.quantile(losses, alpha)
8     es = losses[losses > var].mean()
9     return var, es
10
11 def var_es_parametrique(losses, alpha):
12     """VaR et ES sous hypothese gaussienne."""
13     mu, sigma = np.mean(losses), np.std(losses, ddof=1)
14     z = stats.norm.ppf(alpha)
15     var = mu + sigma * z
16     es = mu + sigma * stats.norm.pdf(z) / (1 - alpha)
17     return var, es
18
19 def var_es_montecarlo(losses, alpha, n_sim=100_000, seed=42):
```

```

20     """VaR et ES par Monte Carlo sur une loi de Student ajustee
      par
21     maximum de vraisemblance (capture la kurtosis elevee des
      rendements)."""
22     df, loc, scale = stats.t.fit(losses)
23     rng = np.random.default_rng(seed)
24     sims = stats.t.rvs(df, loc=loc, scale=scale, size=n_sim,
      random_state=rng)
25     var = np.quantile(sims, alpha)
26     es = sims[sims > var].mean()
27     return var, es

```

A.2 Tests de Backtesting

```

1  def kupiec(N, T, alpha):
2      """Test de couverture inconditionnelle (Kupiec). Loi chi2(1)
      sous H0.
3      N : nombre d'exceptions, T : nombre d'observations."""
4      if N == 0 or N == T:
5          return np.nan, np.nan
6      p_hat, p0 = N / T, 1 - alpha
7      LR = -2 * (N * np.log(p0 / p_hat)
8              + (T - N) * np.log((1 - p0) / (1 - p_hat)))
9      return LR, 1 - stats.chi2.cdf(LR, df=1)
10
11 def christoffersen(exception, alpha):
12     """Test conjoint couverture + independance (Christoffersen).
      Loi chi2(2).
13     Detecte le regroupement des exceptions en clusters (non-
      stationnarite)."""
14     exc = np.asarray(exception).astype(int)
15     T, N = len(exc), exc.sum()
16     n00 = int(((exc[:-1] == 0) & (exc[1:] == 0)).sum())
17     n01 = int(((exc[:-1] == 0) & (exc[1:] == 1)).sum())
18     n10 = int(((exc[:-1] == 1) & (exc[1:] == 0)).sum())
19     n11 = int(((exc[:-1] == 1) & (exc[1:] == 1)).sum())
20     pi01 = n01 / (n00 + n01) if (n00 + n01) > 0 else 0
21     pi11 = n11 / (n10 + n11) if (n10 + n11) > 0 else 0
22     pi = (n01 + n11) / (n00 + n01 + n10 + n11)
23     eps = 1e-12
24     log_indep = ((n00 + n10) * np.log(max(1 - pi, eps))
25                 + (n01 + n11) * np.log(max(pi, eps)))
26     log_full = (n00 * np.log(max(1 - pi01, eps))
27                + n01 * np.log(max(pi01, eps))
28                + n10 * np.log(max(1 - pi11, eps))
29                + n11 * np.log(max(pi11, eps)))
30     LR_ind = -2 * (log_indep - log_full)
31     LR_uc, _ = kupiec(N, T, alpha)
32     LR_cc = LR_uc + LR_ind
33     return LR_cc, 1 - stats.chi2.cdf(LR_cc, df=2)

```

```

34
35 def acerbi_szekely_z2(losses, vars_, ess, alpha):
36     """Statistique Z2 d'Acerbi-Szekely (2014).  $E[Z2] = 0$  sous le
37         modele
38         correct ;  $Z2 > 0$  signale une sous-estimation des pertes de
39         queue par l'ES."""
40     losses = np.asarray(losses); vars_ = np.asarray(vars_); ess =
41         np.asarray(ess)
42     mask = losses > vars_
43     if mask.sum() == 0:
44         return np.nan
45     ratio = (losses[mask] / ess[mask]).sum()
46     return ratio / (len(losses) * (1 - alpha)) - 1

```

A.3 Optimisation CVaR (Rockafellar-Uryasev, programme linéaire)

```

1 def poids_min_cvar(returns, alpha=0.95, w_min=0.0, w_max=1.0):
2     """Minimise la CVaR par programme lineaire :
3
4         min    v + 1/((1-alpha) T) * somme_t u_t
5         s.c.   u_t >= -r_t . w - v,   u_t >= 0
6               somme_i w_i = 1,   w_min <= w_i <= w_max
7
8     Variables : [w (d), v (1), u (T)]. A l'optimum v = VaR et la
9     valeur
10    optimale vaut l'ES. Renvoie (poids, v = VaR, valeur = ES)."""
11    R = np.asarray(returns)           # T x d, rendements (et
12        non pertes)
13    T, d = R.shape
14    nvars = d + 1 + T
15    c = np.zeros(nvars)
16    c[d] = 1.0
17    c[d + 1:] = 1.0 / ((1 - alpha) * T)
18    A_ub = np.zeros((T, nvars))
19    A_ub[:, :d] = -R
20    A_ub[:, d] = -1
21    A_ub[np.arange(T), d + 1 + np.arange(T)] = -1
22    b_ub = np.zeros(T)
23    A_eq = np.zeros((1, nvars)); A_eq[0, :d] = 1.0
24    b_eq = np.array([1.0])
25    bounds = [(w_min, w_max)] * d + [(None, None)] + [(0, None)]
26        * T
27    res = optimize.linprog(c, A_ub=A_ub, b_ub=b_ub, A_eq=A_eq,
28        b_eq=b_eq,
29        bounds=bounds, method='highs')
30
31    if not res.success:
32        raise RuntimeError(f"linprog a echoue : {res.message}")
33    return res.x[:d], res.x[d], res.fun

```

A.4 Allocation d'Euler des Contributions à l'ES

```
1 def allocation_euler_es(losses_per_asset, weights, alpha=0.95):
2     """Contributions d'Euler a l'ES (positivement homogene) :
3
4         rho_i = w_i * E[X_i | X_Pi > VaR_alpha(X_Pi)],  somme =
           ES_alpha(X_Pi).
5
6     losses_per_asset : DataFrame (T x d) des pertes par actif (
           perte > 0).
7     Renvoie (dict {actif: contribution}, total = ES du
           portefeuille)."""
8     L = np.asarray(losses_per_asset)
9     w = np.asarray(weights)
10    port = L @ w
11    var = np.quantile(port, alpha)
12    mask = port > var
13    contribs = {tk: w[i] * L[mask, i].mean()
14                for i, tk in enumerate(losses_per_asset.columns)}
15    return contribs, sum(contribs.values())
```

B Rappels sur les quantiles

Définition B.1 (Fonction de répartition et quantile). Soit X une variable aléatoire réelle. Sa *fonction de répartition* est

$$F_X(x) = \mathbb{P}(X \leq x), \quad x \in \mathbb{R}.$$

Pour $\alpha \in (0, 1)$, le *quantile d'ordre α* de X est

$$q_\alpha(X) = \inf\{x \in \mathbb{R} : F_X(x) \geq \alpha\}.$$

Le quantile $q_\alpha(X)$ est aussi appelé *quantile inférieur* d'ordre α . Il est bien défini pour toute variable aléatoire. Lorsque F_X est continue et strictement croissante, on a simplement $q_\alpha(X) = F_X^{-1}(\alpha)$.

Proposition B.2 (Propriétés élémentaires des quantiles). Soit X une variable aléatoire réelle et $\alpha \in (0, 1)$.

1. $\mathbb{P}(X \leq q_\alpha(X)) \geq \alpha$.
2. Si F_X est continue, alors $\mathbb{P}(X \leq q_\alpha(X)) = \alpha$.
3. Pour $a > 0$ et $b \in \mathbb{R}$: $q_\alpha(aX + b) = a q_\alpha(X) + b$.
4. Si $X \leq Y$ presque sûrement, alors $q_\alpha(X) \leq q_\alpha(Y)$.

Démonstration. *Point 1.* Par définition, $q_\alpha(X) = \inf\{x : F_X(x) \geq \alpha\}$. Pour tout $\varepsilon > 0$, $F_X(q_\alpha(X) + \varepsilon) \geq \alpha$ par définition de l'infimum. Par continuité à droite de F_X , en faisant tendre $\varepsilon \rightarrow 0^+$, on obtient $F_X(q_\alpha(X)) \geq \alpha$.

Point 2. Lorsque F_X est continue, l'ensemble $\{x : F_X(x) \geq \alpha\}$ est fermé et $F_X(q_\alpha(X)) = \alpha$ par continuité.

Point 3. Pour $a > 0$, on remarque d'abord que pour toute fonction de répartition F et tout $\alpha \in (0, 1)$, on a $F(y) \geq \alpha \Leftrightarrow y \geq q_\alpha$, par définition de l'infimum et le point 1. Alors $\mathbb{P}(aX + b \leq x) = F_X((x - b)/a)$, donc $F_X((x - b)/a) \geq \alpha$ équivaut à $(x - b)/a \geq q_\alpha(X)$, soit $x \geq a q_\alpha(X) + b$. Par conséquent $q_\alpha(aX + b) = \inf\{x : x \geq a q_\alpha(X) + b\} = a q_\alpha(X) + b$.

Point 4. Si $X \leq Y$ p.s., alors $F_X(x) \geq F_Y(x)$ pour tout x , donc $\inf\{x : F_X(x) \geq \alpha\} \leq \inf\{x : F_Y(x) \geq \alpha\}$. $\square$

Nous rappelons ici les propriétés fondamentales des quantiles utilisées dans le mémoire.

Soit $F : \mathbb{R} \rightarrow [0, 1]$ une fonction de répartition (croissante, continue à droite, de limites 0 en $-\infty$ et 1 en $+\infty$). Le *quantile inférieur d'ordre α* est

$$q_\alpha^- = \inf\{x \in \mathbb{R} : F(x) \geq \alpha\},$$

et le *quantile supérieur d'ordre α* est

$$q_\alpha^+ = \inf\{x \in \mathbb{R} : F(x) > \alpha\}.$$

Ces deux quantiles coïncident si et seulement si F est continue en q_α^- .

Proposition B.3. Pour tout $\alpha \in (0, 1)$:

1. $F(q_\alpha^- - \varepsilon) < \alpha \leq F(q_\alpha^-)$ pour tout $\varepsilon > 0$.
2. q_α^- est croissant en α .
3. Si F est continue et strictement croissante, $q_\alpha^- = F^{-1}(\alpha)$.

La représentation intégrale de l'ES repose sur le résultat suivant, dit *représentation de Lorentz* ou *de Hardy-Littlewood* :

Proposition B.4. *Pour toute variable aléatoire intégrable X ,*

$$\mathbb{E}[X] = \int_0^1 q_u(X) du.$$

Cela montre que l'ES $\text{ES}_\alpha(X) = \frac{1}{1-\alpha} \int_\alpha^1 q_u(X) du$ est bien une « espérance tronquée en queue ».

Références

- [1] Artzner, P., Delbaen, F., Eber, J.-M., Heath, D. (1999). *Coherent Measures of Risk*. Mathematical Finance, 9(3), 203–228. <https://people.math.ethz.ch/~delbaen/ftp/preprints/CoherentMF.pdf>
- [2] McNeil, A. J., Frey, R., Embrechts, P. (2015). *Quantitative Risk Management : Concepts, Techniques and Tools*. Édition révisée. Princeton University Press.
- [3] Rockafellar, R. T., Uryasev, S. (2000). *Optimization of Conditional Value-at-Risk*. Journal of Risk, 2(3), 21–41. <https://sites.math.washington.edu/~rtr/papers/rtr179-CVaR1.pdf>
- [4] Rockafellar, R. T., Uryasev, S. (2002). *Conditional Value-at-Risk for General Loss Distributions*. Journal of Banking & Finance, 26(7), 1443–1471. <https://sites.math.washington.edu/~rtr/papers/rtr187-CVaR2.pdf>
- [5] Acerbi, C., Tasche, D. (2002). *On the Coherence of Expected Shortfall*. Journal of Banking & Finance, 26(7), 1487–1503. <https://arxiv.org/pdf/cond-mat/0104295>
- [6] Tasche, D. (2002). *Expected Shortfall and Beyond*. Journal of Banking & Finance, 26(7), 1519–1533. <https://arxiv.org/pdf/cond-mat/0203558>
- [7] Acerbi, C., Szekely, B. (2014). *Backtesting Expected Shortfall*. Risk Magazine, December 2014. <https://www.msri.com/research-and-insights/paper/research-insight-backtesting-expected-shortfall-december-2014>
- [8] Gneiting, T. (2011). *Making and Evaluating Point Forecasts*. Journal of the American Statistical Association, 106(494), 746–762. <https://arxiv.org/pdf/0912.0902>
- [9] Fissler, T., Ziegel, J. F. (2016). *Higher Order Elicitability and Osband’s Principle*. The Annals of Statistics, 44(4), 1680–1707. <https://arxiv.org/pdf/1503.08123>
- [10] Delbaen, F. (2002). *Coherent Risk Measures on General Probability Spaces*. In : *Essays in Honour of Dieter Sondermann*, Springer. <https://people.math.ethz.ch/~delbaen/ftp/preprints/RiskMeasuresGeneralSpaces.pdf>
- [11] Kupiec, P. H. (1995). *Techniques for Verifying the Accuracy of Risk Management Models*. Journal of Derivatives, 3(2), 73–84. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=7065
- [12] Christoffersen, P. F. (1998). *Evaluating Interval Forecasts*. International Economic Review, 39(4), 841–862. <https://doi.org/10.2307/2527341>
- [13] Cont, R., Deguest, R., Scandolo, G. (2010). *Robustness and Sensitivity Analysis of Risk Measurement Procedures*. Quantitative Finance, 10(6), 593–606. <https://hal.science/hal-00413729>
- [14] McNeil, A. J., Frey, R. (2000). *Estimation of Tail-Related Risk Measures for Heteroscedastic Financial Time Series : an Extreme Value Approach*. Journal of Empirical Finance, 7(3–4), 271–300. https://faculty.washington.edu/ezivot/econ589/EVT_Mcneil_Frey_2000.pdf